

第十六届中国大学生服务外包创新创业大赛
企业命题类（A 类）

声动课堂

——基于大模型的 AI 语音辅助教学系统

Voice-Activated Classroom

A Large Model-Powered AI Teaching Assistant System

目 录

一、项目概况	1
1.1 项目背景	1
1.2 项目需求分析	5
1.3 可行性分析	11
1.4 项目价值	13
二、项目方案概要	16
2.1 对于项目要求的思考	16
2.2 项目方案简介	16
2.3 方案创新点	18
三、设计思路与技术路线	20
3.1 基于大模型与 RAGFLOW 的 AI 助教系统	20
3.2 基于 FFMPEG 与 SADTALKER 的 PPT 转视频	26
3.3 基于 LIBERSONORA 的有声书字幕生成	28
3.4 基于 SPLEETER 的背景音分离	28
3.5 认知感知型智能推荐系统	32
3.6 音频测试嵌入式平台设计方案	33
四、系统关键技术及其实现	35
4.1 基于大语言模型的可扩展流式语音合成	35
4.2 基于 INFORMER 的深度知识追踪方法	43
4.3 基于 SADTALKER 的虚拟教师技术	46
五、项目规划与团队管理	49
5.1 项目团队成员及角色分工	49
5.2 团队精神和理念	49
5.3 项目进程规划	50
六、“声动课堂”主要功能展示	52
6.1 前端总结构	52
6.2 无障碍适配功能	53
6.3 语音生成功能	54
6.4 音色重塑功能	56
6.5 课件演绎功能	57

6.6 声动教材功能	58
6.7 跟读训练功能	59
6.8 智学对话功能	60
6.9 AI 助学功能	61
6.10 启动 API 服务	62
七、 系统优缺点与未来展望	64
7.1 优点	64
7.2 缺憾与不足	69
7.3 未来展望	69
八、 商业计划	71
8.1 成本分析	71
8.2 市场分析	71
8.3 盈利模式	76
8.4 营销策略	76
九、 参考文献	78

一、项目概况

1.1 项目背景

在当今数字化时代，教育行业正在经历着前所未有的技术革新。随着教育数字化转型的加速，传统教学方式逐渐向智能化、个性化的方向发展。语音合成（Text-to-Speech, TTS）技术和声音克隆技术作为人工智能领域的重要分支，在智能助手、有声阅读、自动播报等领域得到了广泛应用，并在教育领域展现出巨大潜力。

本项目开发一款集大模型技术、AI 语音合成、声音克隆及虚拟数字于一体的教学声音处理软件，旨在为教育内容创作者提供高效、个性化的音/视频生成工具的同时，也为学生提供虚拟教师和教学内容动态讲解的功能，提升其学习体验，助力教育数字化与智能化。为了更好地开展本项目，下文将从政策背景、行业背景和技术背景等多个角度进行深入分析。

1.1.1 政策背景

近年来，国家高度重视教育信息化和数字化转型。2018 年发布的《教育信息化 2.0 行动计划》明确提出，要推动人工智能、大数据等技术在教育中的深度应用，提升教育资源供给能力，促进教育公平^[1]。

在 2022 年 4 月，我国教育部联合其他七个部门共同发布了《新时代基础教育强师计划》^[2]，其中明确提出了深入实施 AI 助推教师队伍建设试点行动的重要任务。这标志着 AI 在教育领域的应用将被提升为国家战略，AI+教育，即 AI 与教学场景的深度融合，将成为未来教育发展的一大趋势。随着这一计划的推进，可以预见学习场景的智能化水平将得到显著提升，个性化教学（因材施教）和优质教育的均衡化将得到更快的推广和实现。

党的二十大报告指出：“推进教育数字化，建设全民终身学习的学习型社会、学习型大国^[3]。”这是以习近平同志为核心的党中央在确定新时代“实施科教兴国战略，强化现代化建设人才支撑”的目标任务时，坚持教育要面向现代化、面向世界、面向未来，对创新教育与学习方式作出的具有前瞻性、全局性的重要战略决策，意义重大而深远。

2025 年全国两会期间，习近平总书记参加政协教育界联组会时作出了重要指示，他提出要实施国家教育数字化战略，建设学习型社会，推动各类型人才竞相涌

现，教育数字化既要“因势而新”，又要“守住根本”^[4]。同时，2025 年全国教育工作会议中也提到要持续推进国家教育数字化战略，助力教育教学深层次变革^[5]。

这一系列政策的出台标志着教育与人工智能的深度融合已成为国家战略级发展方向。而本产品通过 AI 语音合成与声音克隆技术，精准响应政策号召，为教育资源的数字化普惠、个性化教学和教学场景的智能化提供创新解决方案，助力国家教育信息化 2.0 行动计划的落地。

1.1.2 行业背景

据调研，近年来中国声音经济产业规模持续增长，如图 1-1 所示。2022 年已突破 3816.6 亿元，复合年（CAGR）增长率高达 52.15%。其中，AI 配音技术在新兴市场（如有声书和短视频等）的应用虽然规模较小，但增速显著；声音合成技术在教育领域的应用也日益广泛，为教育行业带来了新的发展机遇。

声音合成技术在教育领域的应用多种多样。一方面，TTS 语音合成技术可以将教材中的文字转换为语音，为学生提供生动、自然的朗读体验，尤其对于语言学习者帮助很大。此外，语音辅助学习工具可以帮助学生集中注意力，辅助阅读器则能帮助阅读困难或视觉障碍的学生更好地理解 and 掌握课程内容。另一方面，随着声音经济产业的快速发展，对具备声音合成技能的人才的需求也在逐步增加。这为声音相关行业提供了广阔的市场，涵盖语音技术培训、AI 配音技能教育、智能语音设备应用教学等多个领域。教育机构可以利用先进的教学方法和工具，如在线教育平台和虚拟实验室等，为学生提供更加丰富、互动性强的学习体验，提高教学效果和质量。




图 1-1 2017-2029 年中国声音经济产业市场规模及预测

由此可见，声音合成技术迅猛的发展趋势预示着其在教育领域的巨大潜力。随

着深度学习技术的不断进步，语音合成技术的音质和自然度都在不断提高，为教育行业提供了更高质量的教学工具。

此外，教育行业正处于数字化与智能化转型的关键阶段。图 1-2 和图 1-3 分别为我国 2018~2024 年在线教育市场规模变化情况和在线教育用户规模的变化情况。由图可知，我们近 5 年来在线教育市场快速增长，尤其是 2021 年至今，每年持续递增。根据《中国在线教育行业发展报告（2024）》，2025 年我国在线教育市场规模预计超过 6000 亿元。与此同时，传统课堂教学也在向混合式教学模式转变，教师和学生对于多样化、互动性强的教学资源需求日益增加。




图 1-2 2018-2024 年我国在线教育市场规模变化情况




图 1-3 2018-2024 年我国在线教育用户规模及其同比增速变化

如前所述，声音经济如火如荼发展，在线教育需求日益增大，声音合成与声音克

隆技术在教育领域大有可为。然而，当前的现状是，现有的教育工具在音频内容生成方面尚存在着以下诸多局限：

- (1) 传统的 TTS 声音合成系统音色单一，缺乏个性化和吸引力。
- (2) 音频编辑工具操作复杂，效率低下，易用性差。
- (3) 虚拟教师和数字人技术开发不够充分，尚未广泛应用于实际教学。

在以上这些行业痛点的驱使下，迫切需要开发一款集成语音合成、声音克隆和虚拟数字人展示于一体的教育软件。而本项目的“声动课堂”恰好填补了这一空白，可为教育行业提供一种可行的创新解决方案。

1.1.3 技术背景

1.语音合成与声音克隆技术的演进

语音合成与声音克隆技术的历史十分悠久，其发展历程如图 1-4 所示。该技术最早可追溯至 18 世纪，Von Kempelen 发明了“说话机”，通过机械装置可以模拟人声。20 世纪 60 年代初，Noriko Umeda 开发了首个计算机语音合成系统，奠定数字语音的基础^[1]。70 年代末，贝尔实验室实现了数字化语音合成，但音质仍比较机械。80 年代，Dennis Klatt 开发的 DECtalk 系统问世，它支持文本转语音，但语音生硬如机器人^[7]。




图 1-4 语音合成与声音克隆的发展历程

语音合成与声音克隆技术真正的突破始于 21 世纪深度学习技术的崛起。2016 年

Google 的 DeepMind 发布了重磅技术——WaveNet 声码器模型，首次通过神经网络对原始音频波形直接建模，将计算机输出音频与人类自然语音差距缩小 50%，实现了声音自然度质的飞跃^[8]。2022 年 OpenAI 推出 Voice Engine，仅需 15 秒音频即可生成高精度克隆声线，且支持情感参数调节。2025 年，SparkAudio 团队推出的基于大语言模型的 Spark-TTS 高效 TTS 工具，无需额外的生成模型，直接从 LLM 预测的编码中重建音频，实现零样本文本到语音的转换，支持毫秒级的延迟合成^[9]。该技术结合数字人技术拓展沉浸式的教学场景，标志着语音合成与声音克隆技术进入了“秒级克隆+情感交互”的新阶段。

2. 语音合成与声音克隆核心技术的突破

当前，语音合成与声音克隆技术的突破呈现以下两大特征：

(1) **低样本克隆**。阿里通义实验室的 CosyVoice 模型支持 3~10 秒音频即可生成多语言且情感与语调可控的音色^[10]。

(2) **多模态交互**。语言大模型（例如，DeepSeek 与 ChatGPT）与状态空间模型（State Space Model, SSM）结合，推动了实时对话与个性化的表达；数字人技术通过语音与虚拟形象的融合，打破物理界限，提升了教学场景的沉浸感。

1.2 项目需求分析

1.2.1 用户期望

在教育内容创作与学生学习的实际场景中，用户们面临着多方面的需求与挑战。对于教育内容创作者（如在线课程设计师、培训机构讲师等）而言，他们希望能够以较低的成本和时间投入制作出高质量且个性化的教学音/视频资源；而学生们则渴望有更加生动有趣、互动性强的学习材料来激发他们的学习兴趣并提高学习效率。

基于此，我们总结了以下几个关键的用户期望：

- **提供全新的学习体验**。通过教育软件灵活的语言风格设置，以及教学内容个性化的语音讲解，为学生提供一种轻松的全新的学习体验，提升其学习效率和效果。
- **语言学习辅助**。帮助语言学习者练习发音和语言节奏，如普通话，外语和特定方言等，可以提供更自然流畅的语音样本进行模仿和学习，特别是在语言类课程中尤其有用。
- **特定人群教育辅助**。对于视障或阅读困难的学生，声音克隆技术可以提供文本到语音的服务，帮助他们更好地获取信息和学习。
- **促进教育公平**。在教师资源匮乏的地区，可以利用声音克隆技术创建虚拟教

师，为学生提供高质量、标准化的教学内容。

以上用户期望需要具象化为产品的实际需求。因此，本项目在 1.2.3 节进行了功能需求分析，将以上用户期望进一步详细化和具体化。

1.2.2 应用场景分析

本节针对 1.2.1 节的用户期望，进行了应用场景分析，如表 1-1 所示。

表 1-1 应用场景分析

场景	场景描述	用户需求	功能
场景 1: 视障学生独立学习	视障学生希望能够在没有他人帮助的情况下，在家中通过听觉获取课程内容，并复习相关知识点。	希望通过听觉获取教材内容并能够快速复习知识点，需要一个支持语音导航的平台，支持教材内容识别并转换为语音，帮助其在家中独立完成预习和作业。	平台需提供语音导航和内容朗读功能，支持盲人用户操作。
场景 2: 多语言课堂教学	一名英语教师在国际学校教授学生，班上有来自中国、日本和韩国的孩子。	希望能将课堂讲义转化为中、日、韩三种语言的音频，供学生学习，并确保发音自然且带情感，贴近母语水平。	支持多语言且富有情感的语音合成，生成自然音频。
场景 3: 教师高效备课	教师需要临时出差，准备了上课的 PPT，但是录制讲解视频耗时较长，无法兼顾。	想要快速生成带讲解的课件，用虚拟教师代替自己在课堂上播放，节省人工录制时间。	自动解析 PPT 内容，并生成虚拟教师讲解的内容。
	教师生病，无法亲自到现场讲课。	想要通过教学讲义生成讲解语音，最好可以使用教师本人的声音样本进行克隆，使得学生学习不受换老师的影响。	自动解析 PDF 讲义等文本内容，并通过零样本语音克隆技术生成语音讲解内容。
场景 4: 学生课外阅读	一名小学生课外阅读/学习英语原版《格林童话》。	希望通过听故事音频学习新单词，家长希望音频带字幕并能调整播放速度，跟随字幕练习发音，提升阅读理解能力。	将纸质/电子书籍转为有声书，支持字幕显示和速度调节功能。

场景	场景描述	用户需求	功能
场景 5: 语言考试准备	一名大学生正在备考雅思口语。	希望知道自己的发音准确性是否达标，并在语音回答后希望得到发音评分和改进建议，同时获取相关口语书籍的推荐。	提供录音对比和评分功能，支持语言学习。
场景 6: 个性化教学视频	一名历史教师发现学生对纪录片《长城》的标准解说兴趣不高。	希望将音视频解说替换为学生熟悉的人的声音（例如：任课老师、班主任甚至同学自己等），想保留背景音乐并调整音量，在课堂上播放以提升学生的参与度并加深课堂印象。	替换视频人声，保留背景音并调节音量。
场景 7: 错题解答辅导	一名初中生数学考试后错解“二次方程”类的题目。	希望上传题目图片后获得详细的视频讲解，使得能够理解解题步骤；希望通过语音或者文本提问可以得到实时问答帮助，并可以个性化进行知识点回顾，帮助巩固学习。	生成错题讲解视频，支持多模态交互并部署知识库与大语言模型进行实时回答。
场景 8: 随时学习支持	一名高三学生复习物理课程时有较多疑惑和问题。	希望即时提问并获得解答。	提供全天候的 AI 助学服务，能够回答各类广泛问题。
	教师在备课时好奇“OCR 如何识别手写笔记”这个问题。	希望通过平台获取技术原理，优化教学设计。	

1.2.3 功能需求

基于 1.2.2 节的应用场景，我们提炼出无障碍浏览、语音生成、音色重塑、课件演绎、声动教材、跟读训练、智学对话和 AI 助学 8 大功能点，如表 1-2 所示。

表 1-2 功能需求分析

序号	功能名	功能描述	输入	输出
1	无障碍浏览	视障学生通过屏幕阅读器访问网页，平台能够自动朗读功能界面，帮助他们在课堂外独立完成发音练习或获取有声书资源。	无需用户输入，用户直接与平台交互	自动朗读的音频反馈

序号	功能名	功能描述	输入	输出
2	语音生成	支持文本转语音 (TTS) 与语音克隆双模态输出, 用户可通过网页上传或现场输入文本, 自动生成情感化语音, 支持中/英/日/韩等语言以及一些方言合成。	TXT 文件/文字输入	WAV 格式音频文件
3	音色重塑	支持用户上传音频或视频, 替换人声并保留背景音, 支持背景音与人声大小的分离式一键调节, 适用于教学音/视频个性化。	音/视频文件	重塑音色后的音/视频文件
4	课件演绎	支持 PPT/PDF 文档内容自动解析, 通过 OCR 技术提取文本并生成结构化讲稿; 动态生成 3D 虚拟教师形象, 实现课件内容的自动讲解。	PPT/PDF 文件	带有虚拟教师授课的视频文件
5	声动教材	上传 PDF 版的教材, 通过 OCR 技术识别并提取文字后再转化为音频。支持多文件并行处理, 用户可自定义音频播放速度和音色。音频播放过程中可以实现音频与文字背景标注能同步。	PDF 文件	可视化的音频文件
6	跟读训练	对于单词或句子, 支持用户录音跟读, 并提供用户录音与标准音的对比功能, 从发音准确性、语流流畅度和情感表达三个维度对用户根据录音评分, 支持多种语言, 并根据发音准确度生成课程或推荐书籍。	单词和句子的标准音, 用户跟读的音频文件	发音练习记录, 包括评分与改进建议等
7	智学对话	构建学科知识本体库, 用户上传错题后, 智能匹配错题/知识点与教学案例, 生成动态虚拟教师视频, 支持文本与语音输入。	图片格式的错题	相应错题及其知识点的讲解视频
8	AI 助学	通过点击悬浮小机器人开启 AI 助学对话界面, 利用 NLP 技术理解用户的问题, 并提供答案。	用户的提问	针对用户的问题提供答案和相关信息

1.2.4 系统架构与数据建模

根据以上分析，我们建立了“声动课堂”的系统架构图和全局 E-R 图，分别如图 1-5 和 1-6 所示，来进一步明确我们的系统构建与数据建模。




图 1-5 系统总体架构图




图 1-6 系统全局 E-R 图

1.2.5 性能需求

“声动课堂”的性能需求具体如下：

1. 响应时间

- 定义：从用户输入请求到系统输出结果的总时长。
- 指标：小于等于 2s。
- 场景：教师上传 PPT 生成有声课件，学生请求视频声音置换，需快速响应以保持教学连续性。

2. 自然度 (Naturalness)

- 定义：合成语音的自然程度，包括韵律、语调、停顿等，主观评分基于 5 分制。
- 指标：MOS (Mean Opinion Score) ≥ 4.0 ，通过 speechmetrics 的 mosnet 模型客观评估。
- 场景：学生听有声书或 AI 教师讲解，需感知语音自然流畅，无明显的机械感。

3. 并发处理能力

- 定义：系统同时处理多个用户请求的能力。
- 指标：支持 ≥ 1000 名用户并发访问，响应时间保持 ≤ 2 秒。
- 场景：学校或机构集中使用时，需确保无显著延迟。

1.2.6 其他需求

1. **可靠性需求**。系统应能够稳定运行，确保不因异常情况导致宕机或错误。对于关键操作和数据，系统应提供数据备份和恢复功能，避免因系统故障造成数据丢失。

2. **扩展性需求**。可扩展性强，系统需要支持随着高质量教育题库的不断升级和教育领域的不断变化发展，对模型调优、个性化学习算法等相关部分进行实时迭代升级，以满足未来业务发展需要。

3. **易用性需求**。用户界面友好，简洁明了，易于操作，确保用户可以快速上手；采用良好的可视化交互界面，降低用户使用的操作成本。

4. **可维护性需求**。代码结构清晰，符合规范，方便后期开发维护、漏洞修复和功能迭代。同时，需定期对系统进行测试和维护工作，确保系统运行健康并满足性

能指标。

1.3 可行性分析

1.3.1 技术可行性

1. 核心技术成熟度高

通过调研，我们发现本项目依赖的多项技术均已达到成熟应用水平，能够有效支持项目目标的实现。这些技术覆盖了从音色克隆、语音合成到音频处理和动态展示等多个方面，并已在相关领域验证了其稳定性和可靠性。

- **语音合成与个性化调整。**例如，CosyVoice 声音模型提供零样本音色克隆与语音合成服务，支持高达 16kHz 的高保真音频输出，并能根据需要调整语气和语调变化。Edge-TTS 是另一个开源工具，它基于微软 Azure 的 TTS 技术，可以生成自然流畅的语音，适用于不同语言和方言。
- **音频分离与清晰化处理。**Spleeter 音频分离模型利用卷积神经网络（CNN）将人声与伴奏分离，MOS 评分高达 4.0，确保了教学音频的清晰度和专业性。此外，Audacity 等开源音频编辑软件也可以用于手动或自动化的音频处理任务。
- **虚拟形象创建与动态展示。**SadTalker 虚拟人技术使用 3D 建模与音频驱动技术来实现唇同步及头部动作模拟，帧率可达 30fps，满足虚拟教师的动态展示需求。Blender 和 Unity 这样的 3D 建模和游戏引擎同样可以用来创建高质量的动画内容。
- **教育资源智能化处理。**LiberSonora 模型可以提供智能字幕提取、AI 标题生成及多语言翻译等功能，能够增强教育资源的可访问性。Google Cloud Speech-to-Text API 和 Google Translate API 可分别用于自动生成字幕和多语言翻译。对于 PPT 解析和讲稿生成，LLM 大语言模型可以高效地解析 PPT 并生成接近人工水平的自然讲稿。

2. 技术集成能力强

本项目具备强大的技术集成能力，通过选择合适的编程语言和工具，实现了各个模块间的无缝衔接和高效协作。

- **模块间的无缝协作。**Python 生态系统提供了丰富的库和框架，如 ython-pptx 可解析 PPT 文件，pydub 可处理音频合并，Flask 或 FastAPI 可提供网页交互接口。同时，使用像 ffmpeg 和 libsndfile 这样的开源工具进一步增强了音

频处理的能力，确保从讲稿生成到最终虚拟教师视频输出的完整流程，顺畅无阻。

- **开放标准的支持。** RESTful API 设计使得系统能够轻松与其他教育平台或资源进行整合，扩大了资源的应用范围和影响力。例如，OAuth 2.0 标准可用于安全地管理用户认证和授权，GraphQL 则提供了一种更灵活的数据查询方式，优化了前后端数据的交换效率。

1.3.2 市场可行性

1. 市场前景分析

近年来，在线教育市场不断快速增长。根据《中国在线教育行业发展报告（2024）》，预计到 2025 年我国在线教育市场规模将超过 6000 亿元，年均复合增长率达到 15%。与此同时，混合式教学模式的兴起推动了对智能化教学工具的需求。在用户群体上，教育创作者希望快速生成高质量教学资源，学生则追求个性化、互动性强的学习体验。此外，全球教育科技市场的扩张进一步拓宽了机会，教育数字化的渗透率持续提升。通过开发多语言支持、多功能的教育软件，能够抓住国际市场的增长潜力，吸引海外用户。

2. 同类竞品分析

在竞争格局中，“声动课堂”凭借其强大的技术融合和功能的多样性，具备独特的优势。目前市场上的类似产品有百度的 TTS、Duolingo 和 VTube Studio 等，但它们各自有明显的局限性，具体如下：

- 百度的 TTS 提供语音合成服务，但却缺乏个性化音色支持和虚拟数字人展示功能。
- Duolingo 更多的是专注于语言学习，与“声动课堂”用于综合性教育的目标与定位不同。
- VTube Studio 虽然支持数字人技术，但并未针对教育场景进行优化。

而相比之下，“声动课堂”基于 AI 大模型和多种声音合成及处理技术，提供了从音频输出到虚拟教师视频的完整解决方案，正是这种独特性和创新性使其在教育科技市场中具有一定优势。

1.3.3 经济可行性

“声动课堂”项目启动成本预计约为 150 万元，其中研发费用占主要部分，包括技术开发约 60 万元、团队薪资约 30 万元和测试验证约 10 万元，总计 100 万元。首

年的运营成本预计为 50 万元，涵盖场地租金和服务器费用约 20 万元、技术支持约 15 万元和初步营销费约 15 万元。这些投入为软件的顺利开发和初期市场进入奠定了基础。

收益方面，“声动课堂”通过多元化的收入模式展现出良好的盈利潜力。对于个人用户，其订阅定价为 25 元/月，包年优惠价为 198 元/年。若首年吸引 2000 名用户，年收入可达约 40 万元。针对教育机构的批量授权定价为 10 万元/年，若签约 10 家机构，可带来 100 万元收入。综合估算，首年总收入约为 140 万元。虽然初期收入无法覆盖 150 万元的总成本，但随着用户规模的扩大，次年收入预计增长至 200 万元，累计收益将在第 15 个月（约 160 万元）实现盈亏平衡，显示出项目的中长期经济回报能力。

由以上数据可知，“声动课堂”项目的开发和推广在经济上具有较强的可行性，初始投入与预期收益能够形成了合理的平衡。

1.3.4 法律可行性

“声动课堂”在法律层面具备较高的可行性，能够满足现行法规和政策要求。软件涉及用户上传音色样本和错题资料，数据隐私保护是首要考量。依据《个人信息保护法》，我们采用本地储存而非上传云端的方式，确保用户隐私安全并符合法律标准。同时，软件功能设计与国家教育政策指出的教育数字化与信息化高度契合，充分利用政策的红利，降低了项目风险。

在知识产权方面，项目使用的核心技术需遵循相关许可要求。CosyVoice、Spleeter 和 SadTalker 等技术均为开源，遵循 MIT 或 Apache 许可，允许商业使用，但需保留版权声明并遵守更新条款。开发团队需确保技术集成后的原创性，并申请软件著作权，来避免未来纠纷，这些措施为项目的合法、合规性提供了坚实保障。

1.4 项目价值

1.4.1 用户价值

在当今教育领域，我们深知教师教学任务的繁重，同时学生也面临着多样化、个性化的学习需求。因此，我们精心打造了这款教育领域的声音处理软件，致力于为师生带来全方位的体验和价值提升。

对于教师而言，“声动课堂”能够有效减轻他们的负担，软件可以根据教师提供的课件快速生成教学视频，节省了自己大量手动录制视频的时间，让教师从繁琐、耗时的音频制作工作中解脱出来，把更多精力投入到价值更高的教学设计与学生指

导中。同时，“声动课堂”软件还能弥补真人教师在教学场景中的一些不足之处。例如，在多语言教学环境下，软件可以准确地发出标准的外语发音，为学生提供纯正的语言示范，避免教师因自身发音问题而影响教学效果。“声动课堂”这种新颖的软件能够为课堂教学注入新的活力，增加课堂的吸引力与互动性。

对于学生而言，通过音色重塑等功能，“声动课堂”软件能为他们带来更加个性化的学习体验，增强其学习的趣味性。在语言学习方面，“声动课堂”也展现出了强大的功能，能够精准地捕捉学生的发音细节，提供实时、客观的反馈，帮助学生逐步提升语言发音的准确性，从而解决学生在语言能力提升过程中面临的难题。另外，相比于普通的文字讲解，“声动课堂”软件中的“智学对话”功能通过 AI 教师讲解的方式，帮助其进行题目解析和 AI 讲解，可以更好地帮助学生理解和掌握知识点。而对于视障学生这种特殊群体，“声动课堂”更像是一盏明灯，它能够将文本教材、PPT 课件等教学资源转化为清晰流畅的语音，让这类学生通过听觉也能轻松获取知识，打破其视觉障碍的限制，使其有条件享受到平等的教育机会。

1.4.2 社会价值

“声动课堂”的社会价值主要体现在以下三个方面。

1. 促进跨文化交流，增强全球教育合作

“声动课堂”能够精准地实现多语言转换与交流，打破语言障碍，让不同国家和地区的学生能够轻松地共享优质教育资源。它有利于推动全球教育资源的流动与共享，为跨国教育提供便利，助力全球教育事业的发展。

2. 推广地方语言，促进文化多样性和包容性

“声动课堂”个性化声音设置可支持多种方言，增强包容性，提升教学质量，同时也在保护和推广方言上起到了极大作用，让方言在新时代焕发出新的活力，为文化多样性增添一抹绚丽的色彩。

3. 减少地域教育差距，增强教育公平性

教育公平是社会公平的基石，然而，教育资源的不均衡一直是亟待解决的问题，备受社会关注。“声动课堂”软件通过 AI 虚拟教师技术，使得一些教育资源匮乏的地区也能享受到优质的教育资源，弥补了真人教师不足的问题，能为缩减教育差距和降低教育资源不均衡性助力，增强了教育公平性。

1.4.3 数据价值

“声动课堂”平台积累的教育内容库可用于优化 AI 模型训练，例如，提升 CosyVoice 的音色克隆精度或 SadTalker 的唇同步效果，还可通过授权协议与教育平台合作，生成额外收入，同时为教育技术研究提供高质量语料，助力教学效果、学生偏好及学习模式分析等工作。用户行为数据（例如：软件各功能使用频率、学习时长等）和内容交互数据（例如：错题讲解偏好）等还能支持教育技术趋势研究，揭示 AI 工具对学习成果的影响。

二、项目方案概要

2.1 对于项目要求的思考

项目要求构建一个教学声音处理软件，以 AI 语音合成和声音克隆技术为主，结合教育学原理，充分应用云计算、大数据、大模型、AI 技术、5G、和物联网等新技术为用户提供教学辅助上的帮助，来解决教学效果不足、学习体验单一及教育资源不均衡等问题，目标明确且具社会价值。基于以上需求，本团队对项目提出以下思考。

(1) 项目要求构建声音样本库，提供多种标准音的选择，以及具备音频上传功能与现场录制功能，文件时间长短为 5s-30s。对于标准音的定义需要明确，并且应当涵盖多种语言的标准音；同时，对于上传文件的格式与现场录制功能的文件格式，应该给出提示或者具备一定的兼容性。

(2) 项目要求输出个性化的语音讲解，而何为个性化需要去定义。我们通过采集一些不同风格的音色样本作为本项目的个性化音色，同时支持语速、语调和语气的个性化调整。此外，还可以对文本内容进行 xml 插入，例如：笑声、停顿、重复等，从而实现个性化的语音讲解。

(3) 项目要求完成有声课件的制作，而有声课件具体以什么形式呈现，如何将数字人技术与有声课件结合，如何将课件内容提取生成讲稿后，以视频的方式输出，同时带给同学们交互式课堂的体验，这些内容需要重点考虑。

(4) 项目要求带有声音置换功能与字幕功能，如何在有背景音的情况下完成声音置换，同时支持分离式调整背景音与人声的大小，如何将字幕与我们的产品相结合，做到字幕追踪语音输出，也需要仔细设计。

(5) 关于教育公平的问题该如何体现，本项目建立无障碍浏览模块帮助视障人群进行浏览；同时引入一些方言，帮助教育不发达地区的同学获取更优质的教育资源。

2.2 项目方案简介

2.2.1 系统开发环境

本项目的开发环境及工具链如下：

- 操作系统：Windows 10/11 和 Ubuntu 18.04。

- **前端编程语言:** Python, JavaScript (Vue.js), HTML 和 CSS。
- **后端编程语言:** Python, SQL 和 C。
- **IDE 环境:** Visual Studio Code, PyCharm, Idea, SQL (MyAQL/ PostgreSQL), Chrome DecTools, npm, yarn 和 WebStrom。
- **开发工具:** Miniconda, Docker, Ollama 和 RAGflow。

2.2.2 系统设计方案概述

“声动课堂”，作为一款新颖的基于大模型和 AI 语音技术的教学辅助系统，融合了大模型、语音合成、声音克隆、有声 PPT 及视频生成等先进技术，旨在为教育赋能，推动教育与 AI 技术的深度融合，构建高效的教学模式与个性化的学习生态，助力教育普惠大众。

“声动课堂”以语音技术为基石，构建了一套完整的智能教学体系，其技术架构如图 2-1 所示。系统从基础的语音合成与声音克隆功能，到智能化生成有声教学资源，如 PPT、视频及有声书籍等，再到发音练习、AI 语音讲解以及智能推荐算法，全方位覆盖教学资源生成、辅助学习、智能问答与 AI 教师辅导等环节，形成了一个闭环、个性化的学习流程。

该系统秉持教学公平原则，致力于打破资源壁垒，为学生提供开放、优质的教学资源。同时，系统依托知识库与协同推荐技术，践行因材施教的理念，为每个学生量身定制学习方案，提升学习效率与趣味性。此外，为满足特殊群体需求，系统还特别设计了视障辅助模式与悬浮发音功能，促进教育机会均等，推动教育公平的实现。

在技术实现层面，“声动课堂”搭建了便捷的 Web 端应用平台，并提供语音合成与克隆技术的 API 接口，方便用户集成与使用。同时，该项目具备强大的落地应用潜力，可部署于华为昇腾 310 开发板、人形智能机器人等设备，在具身智能领域展现出广阔的应用前景，紧跟智能教育新时代的浪潮。



图 2-1 “声动课堂”技术架构图

2.3 方案创新点

“声动课堂”AI 语音教学辅助系统的核心创新点如下：

1. 语音合成方面，采用了基于 BPE (Byte Pair Encoding, 字节对编码) 的 CosyVoice2 模型。

相较于其他模型，CosyVoice2 模型具有明显优势，例如：能够有效应对词汇表外单词，简化数据预处理流程，防止发音过长和减少极端情况等。该技术同时具有良好的可控性，能够在输入文本中插入特定标记，达到指定生成语音的方言、并调整语气和音调等效果，操作简便且灵活。该模型还支持流式生成语音，可以实时合成语音，实现低延迟的响应。此外，团队借助 vllm 这一强大的加速工具，CosyVoice2 模型能够进一步提升推理速度。

2. 音频与背景音分离方面，采用了开源高效的 Spleeter 模型。

针对多数模型出现的声音克隆后背景音消失的问题，本项目采用 Deezer Spleeter 音频分离模型。该模型能够将音频的背景精准分离，采用卷积神经网络与分离网络双模态的高效架构，有效学习音频特征的时空模式，保障了分离的精准性。同时系统还实现了多音轨分离，可以满足不同用户对分离音轨的需求。

3. 在识别学生薄弱知识点时，采用了“基于 Informer 的深度知识追踪模型 × RAGflow 动态知识库 × 认知协同过滤”的三维推荐引擎。

本系统采用基于 Informer 的深度知识追踪模型，有效解决了传统预测模型在长序列预测能力不足的弊端，在 IDKT 解码阶段前加入认知编码器，对学生的作答表

现进行更准确的预测。本项目采用“Informer 深度知识追踪 × RAGflow 动态知识库 × 认知协同过滤”的三维推荐引擎，将用户实时行为结合历史用户数据作为数据流，精准识别学生的薄弱知识环节，为学生提供更多相关习题进行强化训练，有效提升学习效果。

4. 在虚拟教师功能上，采用了 SadTalker AI 数字人技术。

为了实现更加逼真的虚拟教师效果以及增强课堂互动性，本系统采用 SadTalker 虚拟数字人技术，实现精准的表情生成以及逼真的头部运动。系统还利用 3D-aware 面部渲染器生成最终视频，在运动同步和视频质量方面达到了良好效果。同时，系统的 LLM 模型支持多模态交互，用户还可以实时与虚拟形象进行语音交互，具备实时解疑答惑的功能。

5. 针对视障人士需求，专门设计了盲人助读辅助功能，且支持硬件部署。

本系统针对视障群体，贴心设计了“高对比度显示”、“盲人读屏”、“十字光标定位辅助”等功能，打破数字世界对视障群体的壁垒。此外，本系统还支持音频质量测试的硬件部署，能够借助高性能计算硬件，拓展更广阔的开发场景。

三、设计思路与技术路线

“声动课堂”系统涉及 AI 大模型应用、TTS 语音合成、PPT 课件解析及视频生成、有声书字幕生成、音频与背景音分离、智能推荐以及音频质量测试的硬件部署等功能，其各部分的设计思路与技术路线如下。

3.1 基于大模型与 RAGflow 的 AI 助教系统

3.1.1 基于 Docker 与 Ollama 的私有化 AI 系统

在数据主权意识觉醒与技术民主化浪潮的双重驱动下，本地部署人工智能与搭建个人知识库正从技术选项演变为数字生存的刚需。云服务虽便利，却暗藏数据失控风险。金融、医疗、法律等敏感领域的企业与个人，通过私有化部署 AI 模型，如 Meta Llama、ChatGLM 等开源框架，可实现数据闭环流转，规避第三方平台隐私泄露与合规审查的隐患。本地算力的进阶迭代，如 NVIDIA Jetson 边缘计算设备，更使模型微调与实时响应成为可能，用户得以根据垂直场景定制专属 AI 助手，而非受限于通用 API 的功能边界。

1. 系统架构与技术栈

本项目的系统架构与技术栈如图 3-1 所示。该构架采用 Ollama 轻量化框架驱动，支持 Llama 3、Mistral 等开源大模型本地化运行，通过量化压缩技术与 GPU 加速实现低资源消耗推理。Open WebUI 提供类 ChatGPT 的友好交互体验，集成对话历史管理、Markdown 渲染及多模态扩展等多种能力，支持上传 WORD、PDF 等多种文本格式，能够进行语音输入以及语音交互对话，充分满足用户需求。另外，系统使用 Docker Compose 一键编排实现环境隔离与快速迁移，保障 AI 服务的稳定性与跨平台兼容性。




图 3-1 系统架构与技术栈

2. LoRA 低秩自适应方法

LoRA (Low-Rank Adaptation, 低秩自适应方法) 作为大型语言模型的高效适配范式, 通过参数空间低秩重构策略, 有效解决了传统全参数微调存在的计算资源消耗大、部署成本高等瓶颈问题。通过这种方法, 可将大模型训练为专精教学问题解答的专家, 根据不同的用户群体设定个性化的回答。该方法的创新性主要体现在以下两个层面:

(1) 模型训练参数效率优化原理

基于对 Transformer 模型参数更新本质的观察, LoRA 提出参数变更矩阵 ΔW 的固有低秩特性假设: 当预训练模型 (参数矩阵为 $W \in \mathbb{R}^{(d \times d)}$) 适配下游任务时, 其有效参数更新量 ΔW 可由低维子空间近似表征。具体而言, 通过引入可训练的低秩分解矩阵 $A \in \mathbb{R}^{(d \times r)}$ 与 $B \in \mathbb{R}^{(d \times r)}$ (秩 $r \ll d$, 典型取值为 $r \in \{1, 2, 4, 8\}$), 构造参数更新路径 $\Delta W = BA$ 。LoRA 参数矩阵示意图如图 3-2 所示。

这种设计将可训练参数量从全参数的 d^2 量级降维至 $2dr$ 量级, 实现 97% 以上的参数冻结率。当 $r = 8$ 时, 训练参数量仅为原模型的 0.16%。




图 3-2 LoRA 参数矩阵分解示意图

(2) 模型训练过程显存优化

LoRA 采用双阶段训练策略，具体如下：

- **参数冻结阶段：**固定预训练模型参数 W ，仅开放低秩矩阵 A 、 B 的梯度计算。
- **参数增量更新：**通过反向传播优化 $\Delta W = BA$ ，使总参数表达为 $W = W + \alpha \Delta W$ (α 为缩放因子)。

该方案在 Adam 优化器环境下，可将训练显存需求压缩至全参数微调的 33% (主要源于优化器状态参数的维度削减)，同时保持与全微调相当的任务性能 (在 GLUE 基准测试中差异小于 1.5%)。

LoRA 这种创新方法不仅显著减少了对 GPU 内存的需求，还提高了模型训练的效率，在保持模型性能的同时，大大降低了参数数量，实现了与全参数微调相当甚至更优的性能。此外，LoRA 的设计允许模型快速切换不同的任务，通过替换不同的矩阵 A 和 B 来实现，极大地降低了存储需求和任务切换开销。LoRA 也展示了与其他参数高效调整方法的兼容性，例如前缀调整 (prefix-tuning)，增加了其灵活性和实用性。

本项目采用 LORA 技术后，LLM 大模型微调前后的对比如图 3-3 和 3-4 所示。

```

### 指令:
请回答以下问题。

### 问题:
1992年四月初九日时生人，女，想了解健康运势

### 回答:
<think>
<思考>
好的，用户提供的信息是：1992年四月初九日时生人，女性，想了解健康运势。首先，我需要确认这个农历日期对应的公历日期，因为四月初九在中国传统历法中属于二月，1992年的四月初九对应的公历日期应该是1992年4月29日。接下来，根据生肖和八字来分析健康运势。1992年是壬申年，生肖属猴，女命的话，五行属火。需要结合年柱、月柱、日柱、时柱来分析。四四月属于二月，天干为壬水，地支为申金。时柱巳火为用神。需要结合这些元素来看健康运势。女性健康运势通常涉及内在五行、情绪状态、生活习惯等方面，需要注意可能的健康问题，比如水火相克导致的消化问题、情绪波动等。同时，分析用神是否得力，比如巳火是否能生扶身体，或者是否有煞星影响健康。

```

图 3-3 LLM 模型微调前




图 3-4 LLM 模型微调后

3. 本项目私有化 AI 系统的核心能力与优势

- **数据主权闭环。**对话数据与微调模型 100%留存本地磁盘，规避云端传输风险，满足金融、医疗等敏感领域的需求。
- **场景定制自由。**支持通过 LoRA 微调、提示词工程与 RAG 检索增强，将通用模型转为知识点解答、代码生成等垂直场景专家。
- **离线生产力工具。**无网络依赖的私有化服务，响应延迟低于 2 秒（实测 RTX 3060+32GB 内存环境），保障核心业务的连续性。
- **持续进化生态。**API 的调用和模块化的设计，支持无缝升级模型版本（ollama pull 指令热加载），可扩展接入 LangChain 等智能体框架。

以通义千问 7b 为例，本项目中部署的本地大模型如图 3-5 所示。




图 3-5 “声动课堂”的本地大模型（以 qwen2:7b 为例）

3.1.2 基于 RAGflow 的私有化知识中枢系统

在当今信息爆炸时代，碎片化数据不断侵蚀注意力与生产力。借助 RAGflow、Logseq 等双向链接工具，构建结构化知识库，本质是建立思维的第二大脑：通过自动化标签体系、语义检索与知识图谱技术，将散落于邮件、文档、会议记录中的隐性经验转化为可追溯、可复用的数字资产。通过知识库与本地 AI 的深度融合，系统可主动分析知识盲区、预测决策路径，生成定制化报告，实现从“人找知识”到“知识找人”的范式跃迁。

本系统采用 RAG（Retrieval-Augmented Generation，检索增强生成）架构。RAGFlow 是一款基于深度文档理解构建的开源 RAG 引擎，可以为各种规模的企业及个人提供一套精简的 RAG 工作流程，结合 LLM 大语言模型，针对用户各类不同的复杂格式数据提供可靠的问答以及有理有据的引用。RAGflow 集成文本向量化、语义检索与大语言模型协同推理能力，支持 PDF/Word/Markdown 等 20 多种格式文档的自动化解析，内置 OCR 识别与表格、公式结构化提取。

本系统中，用户将学习课件 PPT 等资料上传之后，可采用高性能的本地化向量引擎，实现亿级知识片段毫秒级语义匹配。同时，通过与本地 AI 大模型系统无缝对接，支持 LLM 知识增强与问答结果溯源。在用户进行交互时，系统能够准确进行智能检索，从而提供更加专精化的解决方案。

针对长文本和复杂文本的处理，本系统的 RAGflow 采用 RAPTOR 技术，通过递归拆分、聚类 and 摘要，将文档转化为树状结构，快速定位最相关的段落层级，从而更高效地捕捉文本的语义层次。这样解决传统了 RAG 因截断导致的上下文丢失等问题，优化检索增强生成（RAG）的效果。

针对复杂逻辑推理的问答问题，本系统采用知识图谱提取技术，从非结构化文本中抽取实体、关系及属性，构建结构化的知识图谱，将文本转化为语义网络，增强 RAG 系统的逻辑推理能力。

本系统的 RAGflow 通过 Agent 提升自身的自主决策和工具调用的能力，将传统 RAG 升级为更灵活、多步骤的任务处理框架。Agent 本质为一种可编程的“虚拟助手”，能够根据用户目标自主规划任务流程，调用内部工具（如 RAPTOR 检索、知识图谱查询、外部 API 等），并动态调整策略以完成任务。Agent 解决了传统 RAG 单轮检索的局限性，支持多跳推理和长流程任务，如数据分析报告生成等。

本系统的 RAGflow 知识库和 Agent 分别如图 3-6 和 3-7 所示。



图 3-6 RAGflow 知识库




图 3-7 Agent 构建智能学习助手

3.1.3 基于 SoundMatchAnalyser (SMA) 的声音测评

声音测评关键指标详细说明

- **PEAQ (音频质量的感知评估)**: PEAQ 是一种用于评估音频信号感知质量的标准算法。它模拟了人类如何感知音质，并提供了一个分数来指示两个音频信号之间的劣化程度。此指标对于评估音频处理算法对感知音频质量的影响特别有用。
- **LUFs (满量程响度单位)**: LUFs 测量音频信号的感知响度。与简单的音量指标不同，LUFs 考虑了影响人类响度感知的频率和振幅特性，用于评估两个音频文件之间的响度差异，确保音频电平一致。
- **SNR (信噪比)**: SNR 量化了所需信号与背景噪声的比率。较高的 SNR 表示更清晰、更清晰的音频信号。通过比较两个音频文件的 SNR，来确定降

噪和其他音频增强技术的有效性。

- **THD（总谐波失真）**：THD 测量音频信号中存在的谐波失真，以百分比表示。它表示信号由于谐波频率而偏离纯正弦波的程度。较低的 THD 值意味着更高的保真度和更少的失真，使其成为音频质量评估的关键指标。
- **增益调整**：增益调整确定匹配两个信号的音频电平的最佳缩放因子。SMA 会自动计算并应用最佳增益，以使处理后的音频的响度与原始音频的响度保持一致，从而确保公平的比较。
- **MSE(均方误差)**：MSE 计算两个音频信号的相应样本之间的平均平方差。它提供了原始音频和处理音频之间误差的定量测量，MSE 值越低表示再现越准确。

表 3-1 关键指标权重分析表

指标	权重	归一化方法	物理/感知意义
PEAQ	30%	PESQ 值除以 4.55（将 0-4.5 映射到 0-1）	听觉感知质量
LUFS	25%	线性映射 $[-60,0] \rightarrow [0,1]$	响度差异
SNR	20%	截断 40dB 后线性归一化	信噪比
THD	10%	$1 - \text{THD}/10$ ($\text{THD} \leq 10\%$)	谐波失真
MSE	8%	$1 - \text{MSE}/0.01$ ($\text{MSE} \leq 0.01$)	时域波形差异
Scale	5%	直接取值 (0-1)	增益调整幅度
Flatness	1%	二次函数抑制差异	频谱平坦度变化
Centroid	1%	二次函数抑制差异	频谱质心偏移

3.2 基于 FFmpeg 与 SadTalker 的 PPT 转视频

本项目中，基于 FFmpeg 和 SadTalker 的 PPT 课件转视频的总体流程如图 3-8 所示。该流程中的关键步骤如下：

- (1) **PPT 转图片**。使用 VBS 脚本来实现此功能，这些脚本与 PowerPoint 在 Windows

系统中交互。通过调用 ppt2img 脚本，可以生成每张幻灯片的图片。

- (2) **添加音频**。将音频文件与幻灯片对应起来。若某个幻灯片没有音频文件，则会自动生成一个静音音频。然后再将每张幻灯片的图片与音频合成为视频文件。该步骤使用了 FFmpeg 来处理图像与音频的合成。
- (3) **设置转场动画**。本项目通过 FFmpeg 的 xfade 滤镜来控制转场动画的类型（例如 inturn、random 或自定义设置），且可以控制转场动画的持续时间。
- (4) **视频合成**。每张幻灯片图片添加音频后均会生成一段小视频，结合转场动画设置，所有这些小视频片段通过 ffmpeg 命令会被拼接成最终的视频。




图 3-8 PPT 课件转视频的总流程图

- (5) **部署虚拟人**。系统通过 AI 虚拟人技术自动生成带动态讲解的教学视频。其中虚拟教师形象可定制，通过 SadTalker 算法实现精准口型同步、自然表情与头部微动作，最后输出视频采用“画中画”模式，即：课件内容为主画面，

虚拟教师动态讲解窗口嵌入右下角，模拟真实课堂场景。而对于 AI 错题辅导系统，当用户上传题目后，系统自动检测错误并生成解题思路，同时虚拟辅导教师即时启动，基于文本解析结果驱动 3D 虚拟人动作，同步输出语音讲解。该项目支持多模态交互，在教学内容讲解过程中，虚拟教师伴随手势引导、重点标注等教学行为，有效增强知识传递效果。

3.3 基于 LiberSonora 的有声书字幕生成

“声动课堂”有声书生成系统模块，采用了开源的 LiberSonora 模型，实现了智能字幕提取及多语言翻译字幕生成等功能。本系统首先基于 ClearerVoice-Studio 构建了 Clear-voice 模块，对音频进行预处理，有效去除背景噪音并提升音频质量。该模块采用复数域深度学习算法，最大程度地消除了背景噪声，同时确保语音清晰度得以保留。

随后，系统调用了 FunASR 服务来进行语音识别处理。通过使用预训练的语音识别模型，将音频内容准确转换为文字，完成初始字幕的生成工作。为了进一步优化字幕质量，初始生成的字幕文本被输入到大型语言模型（如 Qwen2.5）中，进行断句优化和上下文修正，以确保字幕语义连贯、符合自然语言表达习惯。

对于多语言支持的需求，系统将优化后的字幕文本送入大型语言模型进行翻译，支持多种语言之间的转换，从而满足国际化的需要。

最终，系统将经过优化和翻译的字幕文本与其对应的音频时间轴精确对齐，生成标准字幕文件格式（SRT），确保字幕与音频同步播放。此外，在网页端，通过 JavaScript 代码实现了依据时间戳实时更新高亮显示当前播放句子的功能，增强了用户的阅读体验。

此技术路线不仅提升了从音频到高质量字幕自动化生成的效率，同时也通过提供多语言支持以及播放时的字幕高亮功能，极大地改善了用户体验。

3.4 基于 Spleeter 的背景音分离

在“声动课堂”声音置换模块的开发过程中，由于 CosyVoice2 只能替换人声部分，无法做到保留背景音实现替换，因此我们采用了 Spleeter 音频分离模型^[11]，来实现保留背景音的声音置换功能。

1. Spleeter 模型架构

Spleeter 基于 TensorFlow 开发，采用卷积神经网络与分离网络（Separation

Network) 双模态架构, 其核心模块为 U-Net 网络, 其结构如图 3-9 所示。




图 3-9 Spleeter 的核心模块 U-Net 网络

该网络由一条收缩路径和一条扩张路径组成, 构成了 U 形结构。收缩路径是一个典型的卷积网络, 每个卷积后面跟随一个整流线性单元 (ReLU) 和一个最大池化操作。收缩期间, 空间信息减少而特征信息增加, 而扩张期间, 扩展路径通过一系列上卷积串联操作, 将特征和空间信息与来自收缩路径的特征相结合。Spleeter 通过收缩路径 (特征提取) 与扩张路径 (特征重建) 的级联实现高精度音轨分离。

2. Spleeter 的音频分离核心原理

Spleeter 的音频分离基于深度学习的源分离原理, 通过监督学习从混合音频中提取独立音轨。其核心思想是利用神经网络学习音频特征的时空模式, 生成分离掩码以隔离目标音源。

① 监督学习与损失函数

训练数据为分离音轨对 (例如: 人声和伴奏的独立波形), 通过 STFT 生成对应的谱图。损失函数采用 L1 范数, 计算模型生成的掩码谱图与目标谱图之间的差异, 最小化重建误差, 如式 (3-1) 所示。

$$L = \sum |M_{\text{pred}} \cdot S_{\text{mix}} - S_{\text{target}}| \quad (3-1)$$

其中, M_{pred} 为预测掩码, S_{mix} 为混合谱图, S_{target} 为目标音轨谱图。

② 掩码分离

Spleeter 模型为每个音轨预测一个软掩码 (soft mask, 值在 0~1 之间), 表示该频率分量属于特定音轨的概率。分离阶段通过生成频谱掩码实现音轨分离, 掩码如式 (3-2) 所示。

$$\text{Mask}_v = \frac{E_{\text{voacIs}}}{E_{\text{vocals}} + E_{\text{accompaniment}}} \quad (3-2)$$

其中, Mask_v 表示人声的频谱掩码, E_{voacIs} 表示人声频谱能量, $E_{\text{accompaniment}}$ 表示伴奏频谱能量。

③ 多音轨分离

多音轨分离采用改进版的 U-net 网络, 它由 6 编码层和 6 解码层共 12 层 CNN 组成, 再加入跳跃连接 (Skip Connection), 保留了高频细节。每个音轨对应独立的 U-Net 分支, 通过加权掩码合成最终的分离结果, 同时支持动态调整各音轨的能量权重。

3. Spleeter 音频分离技术优势

- **创新的多模态分离架构。**Spleeter 模型采用双路径 U-Net, 使用独立的网络处理每条音轨的频谱掩码预测, 输出软掩码而非直接预测幅度谱, 保留了混合音频的空间信息; 同时引入多通道 Wiener 滤波 (MWF) 优化掩码合成, 显著提升了 SIR/SAR 指标, 有利于实现高质量的背景音分离。
- **极致的分离效率。**单 GPU 处理 100 秒音频仅需 0.8 秒, 支持 CPU/GPU 混合部署, 兼顾速度与灵活性, 适合教育场景快速生成。
- **开源灵活。**支持模型修改和集成, 具有高灵活性, 适合项目扩展。

4. 模型训练

基于 Spleeter 的背景音分离模型训练流程如图 3-10 所示。训练时的一组数据为 (音乐, 伴奏, 人声), 要求三者时间轴上一致, 提取三者频谱并计算出幅度谱。然后, 模型将音乐幅度谱分别输入到人声 U-Net 和伴奏 U-Net 两个分支中, 得到预测的人声和伴奏结果, 分别计算预测结果和标准结果的 L1 距离并取均值。




图 3-10 模型训练流程图

5. 模型预测

基于 Spleeter 的背景音分离模型预测流程如图 3-11 所示。Spleeter 的预测流程从用户提供的音频文件开始，首先通过短时傅里叶变换（STFT）将音频文件转换为频域谱图，将时间域信号分解为频率和时间的分量，方便后续处理。然后，使用一个基于 U-Net 的神经网络同时预测多个音源的软掩码，如人声和伴奏。这些掩码表示每个频率分量属于特定音源的概率。预测的掩码随后与原始混合谱图相乘，通过加权合成分离出每个音源的频谱部分。最后，通过逆 STFT（iSTFT）将分离的频谱转换回时间域，生成独立的人声和伴奏的 WAV 音频文件。




图 3-11 模型预测流程图

3.5 认知感知型智能推荐系统

“声动课堂”在发音练习和错题讲解时采用认知感知型智能推荐系统，其流程如图 3-12 所示。




图 3-12 认知感知型智能推荐系统流程图

该推荐系统采用“Informer 深度知识追踪 × RAGflow 动态知识库 × 认知协同过滤”的三维推荐引擎，使用改进型的 Informer 架构（IDKT），有效解决长程时间序列预测（LSTF）中长期依赖关系捕捉不足的问题。系统能实时跟踪用户发音练习错误频次、错题对应的知识点以及知识点的停留时长等实时行为数据，嵌入学生相关的认知编码器（SRCE），生成动态认知指纹，通过前馈神经网络预测答题准确率。

本项目的推荐系统采用以下双模态的推荐决策系统：

（1）**利用 RAGflow 进行动态检索**。当检测到用户知识漏洞时，系统会自动激活 RAGflow 的语义检索模块，从存储的教学资源中提取关联材料，通过智能机器人反馈推荐信息给用户，保证了相关推送的准确率和实效性。

（2）**认知协同过滤推荐**。重构皮尔逊相似度计算，将传统习题评分替换为认知指纹相似度，系统能够更加精准地识别薄弱环节。根据用户之间的相似度，算法为目标用户寻找最相似的 N 个用户，并通过认知向量空间映射，发现隐性知识的关联路径，捕捉知识漏洞，实现精准推送。

3.6 音频测试嵌入式平台设计方案

针对当前日益增多的轻量化、便捷化的边缘设备，本系统生成音频的性能指标测试代码部署在 Linux 系统上。系统开发时，该代码已部署到华为昇腾 Atlas 200 DK 开发板上（如图 3-13 所示），以 Ascend 310 芯片的强大算力确保快速、准确地处理

音频数据，从而提供即时的反馈、评价指标和评估结果。




图 3-13 Atlas 200 DK 开发板

在实际应用过程中，高性能硬件和优化的软件环境可以在保证性能指标的条件下稳定运行，系统即使在长时间运行或高负载情况下也能保持良好的性能，并且支持多种开发框架，使得性能测试的部署和集成变得简单快捷。开发人员可以轻松地将性能测试集成到现有的声音处理软件中，而无需进行复杂的配置和调整。

四、系统关键技术及其实现

“声动课堂”采用了基于 LLM 的大模型技术、AI 声音合成技术、声音分离技术、深度知识追踪与协同过滤推荐技术、虚拟教师技术等多项技术，其关键技术及其实现如下。

4.1 基于大语言模型的可扩展流式语音合成

现有的语音模型大多为编解码器语言模型或特征扩散模型。编解码器语言模型利用语音解码器模型提取离散的语音，并且利用自回归模型等来预测语音 Token，然后再利用语音编码器模型将语音 Token 合成为声音波形。而扩散语音模型则用来对齐文本和语音长度，在 E2-TTS 和 F5-TTS 这些模型中，输入的文本带有特殊的 Token，这样就可以更加方便地匹配语音长度。但是这些模型都无法提供很好的情感控制功能和方言生成功能，并且使用的大多是非流式输出，这就导致了无法实时地生成语音，响应时间过慢。

为解决以上问题，本项目提出使用支持流式推理和提示语句生成的 CosyVoice2 模型，该模型可以实时生成音频并且支持情感的控制和方言的合成。CosyVoice2 模型将语音信号的半准和声学信息分开并独立建模。语音生成过程中仅着眼于语义信息，将高级文本 Token 解码为有监督的语义语音 Token。在流式匹配模型中，通过嵌入说话者的声音以及参考音频，生成声学细节（比如音色），将语音 Token 转换为给定说话者的 Mel 频谱^[12]。最后预先训练的声码模型恢复了相位，将 Mel 频谱重新转换为参考音频的声音信号，以达到声音克隆的效果。

4.1.1 文本 Token 的处理

本系统采用的 CosyVoice2 声音模型在文本 Token 处理上采用了字节对编码（Byte Pair Encoding, BPE）技术，这是一种子词标记化方法。BPE 的核心在于通过迭代地合并语料库中出现频率最高的连续字符或词组来构建词汇表^[12]，这种方法特别适用于像中文这样没有明显单词边界的语言。CosyVoice2 模型使用 BPE 技术消除了对前端模型的需求，简化了数据预处理流程。

不同于一些文本语言模型中常用的 Tokenizer，CosyVoice2 特别关注并删除了一对多的 Tokens^[12]。如果某个 BPEToken 包含了多个汉字，它会被屏蔽，以确保每个字符都能被单独编码。这种方式避免了发音过长的问题，并减少了由于数据稀疏性带来的边缘效应。此外，采用文本 Token 让模型能够在端到端的学习过程中直接从

文本输入中学习单词的发音，无需依赖预定义的音素规则，从而提高了模型的灵活性和适应性。这种方法使得 CosyVoice2 在处理多语言文本到语音转换任务时更加高效和精确。

表 4-1 为 BPE 技术的优化效果，可以看出它可以明显降低错误率。

表 4-1 BPE 优化效果

改进项	数据指标	数值对比
端到端 BPE 分词	CER（内容一致性误差）	3.63% → 1.45%（错误率下降 60%）
中文多字符拆分	CER（内容一致性误差）	11.75% → 6.83%（错误率下降 42%）

4.1.2 有监督的语义语音 Token

有监督的语义语音 Token 通过 FSQ（Finite Scalar Quantization，有限标量量化）量化和 ASR（Automatic Speech Recognition，自动语音识别）监督，从语音信号中提取高层次的语义信息，并将其量化为离散的语音 Token^[13]。这些 Token 捕捉语音的核心语义内容，为后续语言模型生成一致、自然的语音提供基础，实现了高效、精准的语义编码，不仅解决了传统方法的局限性，还支撑了模型的扩展性、多语言能力与流式合成特性。

有监督的语音 Token 的具体实现流程如图 4-1 所示。输入的语音信号经过第一个编码器，进入 FSQ 循环处理语音标记。精炼的语音特征通过 FSQ 传给第二个编码器，然后通过 ASR 解码器输出最终的音频。




图 4-1 监督的语音 Token

图 4-1 中对 FSQ 模块中间表示 H 的处理流程分为以下三步^[14]：

- (1) **降维**: 将原始的中间表示 H 通过一个映射投影到 D 维的低秩空间。
- (2) **量化**: 在低秩空间中, 每个维度的值都会被量化到区间 $[-k, k]$ 之间。
- (3) **恢复原维度**: 量化后的低秩表示 $\bar{H}$ 会再投影回原始的高维空间, 生成 $\hat{H}$, 用于后续模块的处理。 $\bar{H}$ 和 $\hat{H}$ 的表示如式 (4-1) 和 (4-2) 所示。

$$\bar{H} = \text{ROUND}(\text{Proj}_{\text{down}}(H)) \quad (4-1)$$

$$\hat{H} = \text{Proj}_{\text{up}}(\bar{H}) \quad (4-2)$$

在训练时, 由于 FSQ 和 Encoder1 涉及量化操作, 无法直接计算梯度, 因此使用 STE (直通估计) 来近似梯度, 使其能通过反向传播优化。语音 Token u_i 的计算方法如式 (4-3) 所示:

$$u_i = \sum_{j=0}^{D-1} \bar{h}_{i,j} (2k+1)^j \quad (4-3)$$

表 4-2 为传统向量量化方法 VQ (Vector Quantization) 和 FSQ 的效果对比, 可以看出 FSQ 的效果明显优于 VQ 方法。

表 4-2 VQ 与 FSQ 量化方法效果对比

指标	VQ (传统向量量化)	FSQ (有限标量量化)	相对提升
码本利用率	23% (963/4096)	100% (6561/6561)	利用率提高 77%
ASR 错误率 (C.V. EN)	18.26%	10.67%	准确率提高 41.6%
ASR 错误率 (C.V. CN)	11.56%	7.29%	准确率提高 36.9%
ASR 错误率 (Fluers EN)	7.65%	6.58%	准确率提高 14%
ASR 错误率 (Fluers CN)	5.03%	4.43%	准确率提高 11.9%

4.1.3 流式输出的实现

对于非流式模式, 整个输入文本在生成过程中是已知的, 因此可以直接将文本 Token 与语音 Token 按顺序拼接, 模型只需预测每个 Token, 直到达到“结束符”。而流式输出的实现主要通过统一的文本-语音语言模型以及块感知因果流匹配模型。通过流式输出可以实现实时的生成音频, 提高了系统的响应速度。图 4-2 为流式和非

流式的文本转语音模型，通过嵌入文本进行推理得到声音 Token。




图 4-2 文本转语音模型

在流式模式中，输入文本是以流的形式输入模型，而不是事先知道完整的句子。在该模式下，文本和语音 Token 是以预定义的比例（例如，每 5 个文本 Token 后跟随 15 个语音 Token）交替生成。如果下一个 Token 是文本 Token，模型预测一个填充 Token，表示下 N 个文本 Token 将在推理阶段拼接。当文本 Token 用尽后，模型会生成“语音转折符”和剩余的语音 Token，从而形成混合的文本-语音 Token 序列^[12]。

4.1.4 流式匹配的实现

图 4-3 为流式匹配模型，该模型通过分块处理语音特征，逐步生成 Mel 频谱图，实现低延迟的实时语音合成，并且支持四种掩码模式（非因果、全因果、分块-M、分块-2M），覆盖从极低延迟到高质量合成的需求，灵活适应不同场景。




图 4-3 流式匹配模型

CosyVoice2 中采用 Mel 频谱图作为声学特征，帧率为 50Hz，采样率为 24000。

由于语音标记（25Hz）和 Mel 特征之间的帧率不匹配，将语音标记上采样两倍以匹配 Mel 频谱图的帧率。在上采样操作之前，添加了一个额外的前瞻卷积层，以便为后续的因果模块提供未来信息。该前瞻层通过一个右填充的 1-D 卷积实现，填充大小为 P ，卷积核大小为 $P+1$ 。之后，跟随几个块感知的因果 Transformer 块，以对齐语音标记的表示空间，使其与声学特征匹配^[12]。

本项目中使用条件流匹配（CFM）模型，以语音标记、参考语音和说话人嵌入为条件，对 Mel 频谱图进行采样。在 CFM 模型中，目标 Mel 频谱图的分布由从先验分布 $p_0(x)$ 到数据分布 $q(x)$ 的概率密度路径描述。该概率密度路径可以通过一个时间依赖的向量场来定义。为了提高采样效率使用最优传输（OT）流来匹配由常微分方程（ODE）给出的向量场。然后进一步优化 U-Net 参数。在条件和非条件情况下训练模型，而在推理期间，采用余弦调度程序来计算时间分布。

4.1.5 提示语句生成

CosyVoice2 模型的提示语句主要是通过通过在输入文本中插入特定标记来实现对语音合成效果的控制，这些标记可以指定生成语音的方言、语气、音调等效果，甚至可以插入停顿或笑声等语气词。例如，通过在文本中加入“用四川话说这句话<|endofprompt|>”这样的标记，模型能够识别并切换到指定的方言进行语音合成。同样地，使用像“[laughter]”这样的标记，可以在生成的语音中添加笑声或其他语气词，增加语音输出的自然度和表现力。

当模型接收到含有提示语句的输入文本时，首先会对文本进行规范化处理，包括去除空白字符和替换标点符号等步骤。然后，模型会识别出文本中的特殊标记，并将它们与普通文本内容分离^[12]。例如，“用四川话说这句话<|endofprompt|>”中的指令部分会被单独识别出来。基于提取出来的提示语句，模型调整语音合成参数以适应不同的方言、语气或音调需求。如果指示要求使用四川话，那么在生成语音时就会切换到对应的四川方言模式。最终，根据提示语句的要求和文本内容，模型生成相应的语音输出，确保语音包含用户指定的方言、语气或音调特点。

指示语句的一个显著优势是极大地增强了语音合成的可控性。用户只需简单地插入特定标记，就可以轻松指定语音风格、语气或方言，而无需深入了解模型内部机制。这种方式让 CosyVoice2 在执行多语言、多风格的语音合成任务时表现出色。此外，指示语句还支持流式语音合成，允许在语音生成过程中实时调整效果，比如根据用户插入的停顿标记（如“[pause]”）实时调整语音中的停顿时间。通过以上这些机制，CosyVoice2 模型就能灵活响应用户在语音合成方面的多样化需求，同时保证语音输出既高效又自然。

4.1.6 SFT 的强化学习

通过强化学习，本模型能够更精准地模仿目标说话者的音色、语调和风格，提升生成语音的个性化表现，优化相似性。通过引入 ASR 奖励函数，可以直接优化语音内容与输入文本的一致性，降低生成词错误率。

在 CosyVoice2 中采用说话者的相似性（Speaker Similarity, SS）和来自 ASR 系统的识别单词错误率（Word Error Rate, WER）作为奖励函数以提高在微调阶段说话者的相似性和发音清晰度^[12]，使用 WER 和 SS 来区分优选样本 x^w 和被拒样本 x^l ，并采用 DPO（Direct Preference Optimization，直接偏好优化）进行优化^[15]，如式（4-4）所示。

$$L_{DPO}(\pi_{\theta}; \pi_{\text{ref}}) = -\log \sigma(\beta \log \frac{\pi_{\theta}(\mu^w|y)}{\pi_{\text{ref}}(\mu^w|y)} - \beta \log \frac{\pi_{\theta}(\mu^l|y)}{\pi_{\text{ref}}(\mu^l|y)}) \quad (4-4)$$

其中， u^w 和 u^l 是从优选样本 x^w 和被拒样本 x^l 中提取的语音 Token，但是这样的方法需要反复合成语音并通过 ASR 计算 WER 和 SS，导致训练过程计算量过大。于是本项目使用 LM 直接预测语音 Token u_i ，再恢复低秩表示 $\bar{H}$ ，而不是直接合成音频，然后使用 ASR 重新预测文本，如式（4-5）~（4-7）所示。

$$\bar{h}_{i,j} = \lfloor \frac{\mu_i}{(2K+1)^j} \rfloor \bmod (2K+1) \quad (4-5)$$

$$\hat{H} = \text{Proj}_{up}(\bar{H}) \quad (4-6)$$

$$L_{ASR} = -\log P(Y | \hat{H}; \theta_{ASR}) \quad (4-7)$$

4.1.7 vLLM 加速技术的应用

vLLM（Virtual Large Language Model，虚拟大语言模型）是伯克利大学 LMSYS 组织开源的大语言模型高速推理框架，是一种专为大型语言模型设计的高效推理库，旨在极大提升实时场景下的语言模型服务的吞吐与内存使用效率。vLLM 是一个快速且易于使用的库，用于 LLM 推理和服务，可以和 HuggingFace 无缝集成。vLLM 利用了全新的注意力算法 PagedAttention，有效地管理注意力键和值，显著提升了模型的推理速度和资源利用效率。图 4-4 展示了 vLLM 与其他同类方案的对比。由图可知，在吞吐量方面，vLLM 的性能比 HuggingFace Transformers（HF）高出 24 倍，比文本生成推理（TGI）高出 1.5 倍。




图 4-4 不同技术方案推理性能对比

为了优化 CosyVoice2 模型的推理速度，可以使用 vLLM 加速技术从以下几个方面进行优化。

1. PagedAttention 技术优化

PagedAttention 是一种受操作系统中虚拟内存和分页技术启发的注意力算法，是 vLLM 的核心创新之一。它通过将键（Key）和值（Value）张量进行分块处理，每个块包含固定长度的 Token，从而高效地管理内存。这种方法类似于操作系统中的虚拟内存和分页机制，允许在非连续的内存空间中存储连续的 KV 张量。

vLLM 通过 PagedAttention 技术高效地管理 Attention 中缓存的张量。通过分块和非连续存储，PagedAttention 减少了内存碎片，提高了内存利用率，解决了 LLM 服务中内存的瓶颈问题，使得推理速度大幅提升。在实际应用中，vLLM 的吞吐量比 HuggingFace Transformers 高 14-24 倍，并且 PagedAttention 允许更灵活的内存分配和管理策略，这对于处理变长序列和批量处理多个请求特别有利。

2. Continuous Batching 优化

Continuous Batching 是一种在大模型推理中优化计算效率的方法。它通过将多个推理请求组合成一个批次进行处理，从而充分利用计算资源，提高推理速度和吞吐量。

当推理请求到达时，Continuous Batching 技术会将请求暂存到一个缓冲区中，而不是立即为其分配计算资源。根据系统的负载情况和预设的批次大小，动态调整等待时间和批次大小。当系统负载较高时，减小等待时间并增加批次大小；反之，当系统负载较低时，增加等待时间并减小批次大小。在等待时间结束后，将缓冲区中的请求组成一个批次进行推理，充分利用硬件的并行计算能力。

vLLM 采用 Continuous Batching 技术，传入的请求被连续批处理在一起，最大限度地提高硬件利用率并减少计算浪费，从而进一步提升推理速度。

3. 多步调度优化

vLLM 在 0.6.0 版本中引入了多步调度技术，一次调度后可以执行多步推理，从而显著提高并发处理能力。例如，在 4 张 H100 环境下运行 Llama 70B 时，多步推理的吞吐量比单步推理提升了 28%。

在本项目的测试中，进行非流式推理时，运行单任务推理 rtf 能从原来的 0.25~0.30，经过 vLLM 加速后能达到 0.1~0.15。加速后进行流式推理，首包延迟能在 250~350ms 之间，相比非流式推理有所增加，但整体性能得到优化，平衡了流式推理的实时性和资源消耗。而且非流式并发能够有效支持 20 个并发 ($rtf < 1$)，流式并发支持 5 个并发，相比原始模型，其并发处理能力得到显著提升。

4.1.8 模块消融研究

我们对文本语音语言模型进行了模块化消融研究，以评估我们的修改效果，包括 LLM 初始化、移除说话人嵌入和利用 FSQ 量化。通过用预训练的 LLM 替换随机初始化的语言模型，我们在 test-zh 和 test-hard 集上分别相对提高 18.46% 和 15.40%。然后，我们从文本到语音语言模型中移除了说话人嵌入，这有助于防止上下文学习中的信息泄露和干扰。这一变化导致内容错误显著减少，同时保持了说话人相似性。最后，通过用 FSQ 替换 VQ，内容一致性得到显著提高，说话人相似性保持不变。通过充分利用代码本，FSQ 捕捉到更多内容信息和上下文变化，使得文本和语音标记之间更好地对齐。此外，我们在基于 FSQ 的语音分词器训练过程中引入了音高损失作为约束条件进行了比较实验，发现这种方法在下游 TTS 任务中的性能得到了提升。表 4-3 是消融实验结果。

表 4-3 消融实验结果

模型	test-zh		test-en		test-hard	
	CER(%)	SS	WER(%)	SS	WER(%)	SS
CosyVoice	3.63	0.775	4.29	0.699	11.75	0.755
+ LLM init	2.96	0.808	4.57	0.730	9.94	0.789
+ Drop Spk Emb	2.56	0.804	3.81	0.740	9.66	0.778
+ FSQ	1.45	0.806	2.57	0.736	6.83	0.776
+ Pitch Loss	1.19	0.802	2.40	0.728	6.29	0.769

4.2 基于 Informer 的深度知识追踪方法

现有知识追踪方法，如循环神经网络（Recurrent Neural Network, RNN）、键值记忆网络（Key-Value Memory Networks, KVMN）和 Transformer，在长序列时间序列预测（LSTF）中存在长期依赖关系捕捉不足的问题。尽管 Transformer 在 LSTF 能力上优于 RNN 和 KVMN，但仍面临高时间复杂度、内存占用大和推理速度慢等挑战。此外，现有模型多依赖学生历史答题记录，忽视了个体认知能力对作答表现的影响，导致预测效果不佳。

为此，本系统使用基于 Informer 的深度知识追踪模型（Informer-based Deep Knowledge Tracing, IDKT）^[16]，通过引入 Informer 网络来提升长序列预测能力，降低时间与空间复杂度，并加快推理速度。在 IDKT 解码阶段前加入学生相关认知编码器（Student-Related Cognition Encoder, SRCE），评估学生个性化认知能力以提升预测性能。IDKT 模型包含交互嵌入层（Interaction Embedding Layer）、Informer Block 层、SRCE 和前馈层四个模块，如图 4-5 所示。




图 4-5 IDKT 模型构架

4.2.1 基于历史学习记录的知识点掌握建模与嵌入表示

本系统通过学生的历史学习记录（包括答题序列和正误情况）和用户行为输入的实时数据流来模拟其知识点掌握情况。IDKT 模型的交互嵌入层以学生的答题交互为输入（在本系统中为学生的发音练习和上传的错题）。由于 Informer 无法直接获取位置和时序信息，所以同样将位置嵌入信息（ $PE_{q_t} \in \mathbb{R}^d$ ）和时间嵌入信息（ $TE_{q_t} \in \mathbb{R}^d$ ）一并送至交互嵌入层，得到单个试题-反应交互的嵌入向量 $\hat{x}_t \in \mathbb{R}^d$ ，如式（4-

8) ~ (4-10) 所示。

$$\hat{q}_\tau = W_{Emb_q} * q_\tau + b_{Emb_q} \quad (4-8)$$

$$\hat{x}_\tau = [\hat{q}_\tau * r_\tau] \oplus [\hat{q}_\tau * (1 - r_\tau)] \quad (4-9)$$

$$\hat{x}_\tau = W_{Emb_x} \hat{x}_\tau + b_{Emb_x} + PE_{q_\tau} + TE_{q_\tau} \quad (4-10)$$

将交互嵌入层得到的相关向量（如试题嵌入 $\hat{q}_\tau$ 、交互嵌入 $\hat{x}_\tau$ 等）送至 Informer Block 中进行学习，最终经过 Normalization 归一化输出结果，并经过一个全连接层之后得到学习者的隐藏知识状态表示 $h\tau$ 。

4.2.2 学生相关认知编码器

图 4-7 为学生相关认知编码器 SRCE 的完整结构。其输入为 Encoder 输出的 Z 矩阵，通过不断迭代训练，最终得到学生随着时间流逝而变化的认知能力 $CE = \{\hat{c}_1, \hat{c}_2, \dots, \hat{c}_t\}$ 。即在学生相关认知编码器中首先设置了一个待训练的认知矩阵 $M_c \in R^{l \times a}$ ，然后 SRCE 模块从认知矩阵中选取代表学生个性化认知水平的向量 $\hat{c}_t$ ， $\hat{c}_t = M_c[idx_x]$ 。 $idx_x \in [0, t]$ 表示该学生在时刻 t 时认知能力的对应索引值。将 Encoder 输出的结果 Z 输入到映射函数 f_p 来得到学生个性化认知能力向量的索引概率分布，接着从该分布中选取对应的索引 idx_x 。




图 4-6 学生相关认知编码器 SRCE 结构

4.2.3 基于前馈神经网络的作答表现预测

前馈神经网络（Feed Forward Neural Network, FFN）有助于在模型中加入非线性，考虑特征向量不同潜在维度之间蕴含的丰富信息。因此，本项目在 IDKT 结构的解码器后面连接一个前馈层作为 IDKT 模型的预测层。它由两个线性变换组成，并在两个线性变化层之间添加了一个 ReLU 激活函数来引入非线性。然后将上述解

码器的输出送至前馈神经网络中,进而得到表示学生的学习表示向量 $f_t \in R^{d_{FFN}}$; 如式 (4-11) ~ (4-12) 所示。

$$f_t = FFN(LayerNorm(h_t)) \quad (4-11)$$

$$FFN(\cdot) = Linear(ReLU(Linear(\cdot))) \quad (4-12)$$

其中, d_{FFN} 表示前馈层的嵌入维度, $LayerNorm(\cdot)$ 表示层归一化操作。最后, 将上述学习表示 f_t 和学生隐藏知识状态 h_t 拼接后, 送入一个具有 Sigmoid 激活的全连接网络来预测学生的作答表现 $\tilde{p}_t \in [0,1]$, 如式 (4-13) 所示。

$$\tilde{p}_t = \sigma[(f_t \oplus h_t) * W_p^{pred} + b_p^{pred}] \quad (4-13)$$

其中, $W_p^{pred} \in R^{(d_{FFN}+d) \times 1}$ 和 $b_p^{pred} \in R$ 分别表示权重和偏差项, $\tilde{p}_t$ 是一个标量, 表示学习者在 t 时刻正确回答试题的概率, $\sigma(\cdot)$ 表示 sigmoid 函数。

4.2.4 基于学生用户的协同过滤推荐算法

协同过滤算法是推荐系统中的一种核心算法, 其通过分析用户的历史行为数据来预测用户可能感兴趣的项目, 该算法主要依赖用户之间的相似性或项目之间的相似性来生成推荐。

本系统中基于学生用户的协同过滤推荐算法分为以下两个大致步骤:

(1) **学生用户的相似度计算**: 确定用户之间的相似度, 通过计算用户评分向量之间的相似度来实现。

(2) **推荐生成**: 根据用户之间的相似度, 算法为目标用户找到最相似的 N 个用户。

传统的用户相似度计算方法如式 (4-14) 所示:

$$Sim(u, v) = \frac{\sum (u_i - \bar{\mu}) \cdot (v_i - \bar{\nu})}{|u_i - \bar{\mu}| \cdot |v_i - \bar{\nu}|} \quad (4-14)$$

式 (4-14) 中采用皮尔逊相关系数来对用户相似度进行计算。其中, u_i 和 v_i 分别表示用户 u 和用户 v 对项目 i 的评分, 取值范围为 $0 \sim 1$; $\bar{\mu}$ 和 $\bar{\nu}$ 分别表示用户 u 和用户 v 对所有做过的项目的平均评分值, 值范围为 $-1 \sim 1$, 结果越接近 1, 两者相关性就越强, 也就越相似。

基于传统用户过滤算法, 本系统采用学生认知水平计算预测结果^[17], 即: 将学生用户对于某一知识点的认知水平结合进来, 替换公式 (4-14) 中用户 u 的习题评分, 最后根据计算出的相似度为学生用户 u 提供相应的习题推荐。改进的相似度计算方法如式 (4-15) 所示:

$$Sim(u, v) = \frac{\sum p_{u,i} \cdot (v_i - \bar{\nu})}{p_{u,i} \cdot |v_i - \bar{\nu}|} \quad (4-15)$$

其中, $p_{u,i}$ 表示学生 u 对习题 i 的知识水平预测。系统将学生对特定知识点下习题的练习频率转化为评分指标: 练习次数越多, 评分越高, 表明学生对该知识点的掌握程度不足, 需要更多练习。基于此算法, 系统将通过分析练习频率, 精准识别薄弱知识点, 从而有针对性地推荐更多的相关习题, 帮助学生加强薄弱环节, 克服学习障碍, 提升学习效果。


4.3 基于 SadTalker 的虚拟教师技术

本系统中的虚拟教师采用 SadTalker 技术。其可以根据上传的图片和音频, 利用 ExpNet 及 PoseVAE 分别生成 3DMM 运动系数, 利用三维面部渲染器生成视频。单张图像与音频驱动的 3D 人脸视频生成流程如图 4-7 所示。

SadTalker 建模音频与不同类别运动场系数之间联系, 蒸馏运动场系数与三维人脸渲染, 学习准确的面部表情。对于头部姿势, 设计 PoseVAE 生成不同风格的头部动画, 最终生成的三维运动场系数映射至面部渲染器的三维关键点空间进行生成视频。在 3DMM 中, 三维面部 shape S 可解耦为式 (4-16) 的内容:

$$S = \bar{S} + \alpha U_{id} + \beta U_{exp} \quad (4-16)$$

其中, $\bar{S}$ 表示 3D 人脸的平均 shape, U_{id} 表示形状正交基, U_{exp} 表示表达正交基, α 、 β 为相关系数。



4.3.1 表情系数 ExpNet

通常来说, 通过音频生成准确表情相关参数有以下两个难点:

- (1) 不同人体音频到表情有不同表现。
- (2) 表情中有些与音频无关动作, 这影响预测的准确性。

本系统中使用表情系数 ExpNet 来降低这些不确定性。输入音频被分割为 t 个时

间片段，每个片段对应 0.2 秒的梅尔频谱图。训练时，利用一个基于 ResNet 的音频编码器将音频片段映射到一个隐空间，然后线性层作为一个映射网络解码表情系数^[18]，如图 4-8 所示。

为了保证个人特征，通过第一帧的表情系数 β_0 建立表情和特定人身份的关联，训练时仅使用唇部作为真值。引入眨眼控制信号 z_{blink} ，并通过眼部关键点损失函数约束生成眨眼的自然性与同步性，如式 (4-17) 所示：

$$\beta_{\{1,...,t\}} = \Phi_M(\Phi_A(a_{\{1,...,t\}}), z_{blink}, \beta_0) \quad (4-17)$$

为了减少说话时其他面部成分的表情权重，利用预训练的 Wav2lip 生成的嘴唇运动系数作为 target，其他微表情通过额外关键点损失约束。




图 4-8 音频驱动的面部表情系数映射测试结构

4.3.2 头部姿势 PoseVAE

图 4-10 为基于 VAE(Variational Auto-Encoder, 变分编码器)的模型——PoseVAE，用于学习逼真的有个性风格的头部运动。PoseVAE 模型以 n 帧头部姿势序列作为训练数据，编码器与解码器的输入均为 t 帧时序姿势。在训练阶段，编码器将 t 帧姿势映射到潜在空间，解码器则通过采样潜在分布重建 t 帧姿势，从而学习头部运动的概率分布特性。对于头部运动的生成，PoseVAE 不直接生成姿势，而是学习与第一帧姿势 p_0 之间的残差，通过逐帧迭代生成残差并叠加至前一帧的预测结果，逐步扩展生成远超训练帧数 (t 帧) 的长序列。残差约束有效抑制了误差累积，避免了传统自回归模型常见的“运动漂移”问题，最终输出连续稳定且符合个性化风格的头部运动序列。




图 4-9 音频驱动下 3D 姿态系数 VAE 编解码训练及测试结构

4.3.3 3D-aware 面部渲染

头部视频合成模型 Face-vid2vid 需要真实视频作为驱动信号,而 SadTalker 所用的面部渲染器利用 3DMM 参数进行驱动,通过 mappingNet 来学习 3DMM 运动系数（头部姿势和表情）和 3D 关键点之间的关系,如图 4-10 所示。




图 4-10 映射网络学习 3DMM 运动系数与无监督 3D 关键点之间的关系

训练过程分两步：第一步自监督训练 face-vid2vid；第二步 frozen 外观编码器、关键点估计、图像生成模块参数进行微调，然后通过重构的方式训练映射网络，在关键点空间使用 L_1 loss 约束。

五、项目规划与团队管理

5.1 项目团队成员及角色分工

本项目的成员及角色分工如表 5-1 所示。

表 5-1 项目团队成员及角色分工

姓名	角色	项目分工
小杨	队长	负责技术架构设计、资源协调与成员相互沟通，善于在快速迭代中平衡需求与团队效率。
小何	副队长	是技术与协作的“双面能手”，负责深入代码层解决问题、高效分解任务、衔接队员间的协作。
小马	队员	兼具后端 API 开发与 DevOps 部署经验。主导数据库设计与云服务搭建，为团队引入自动化工具，提升整体开发效率。
小沈	队员	专注于机器学习模型的高性能部署与工程化落地。擅长 PyTorch/TensorRT 模型优化、CUDA 加速和分布式推理框架。
小林	队员	喜欢设计 UI、玩建模的视觉系程序猿，对于任何工作要求都会尽力完成。

5.2 团队精神和理念

我们的团队名为“声动学堂小分队”，“声”代表智能声音技术，“动”代表虚拟教师技术。这一名称围绕着本系统的核心技术——TTS 语音合成所展开的一系列教育创新实践，也表达了我们作为计算机学子，致力于以自身才能为社会创造价值的坚定目标。

作为一个团队，我们充分发挥每位成员的特长，明确分工、各司其职，同时注重协同合作，从而确保团队的高效运转。因此，合作是我们团队精神的核心。完成项目并追求卓越，是我们共同的使命。在开发过程中，面对技术难点，我们共同分析问题、寻找解决方案，积极沟通、互相勉励；面对不同观点，我们倾听彼此意见，理性辩论而非固执己见。我们是一个集体，为共同目标而奋斗；我们也是独立的个体，百花齐放、求同存异，在协作中实现个人与团队的共同成长。

其次，创新意识是我们团队精神的重要组成部分。为了追求卓越，我们定期召开会议，集中讨论，鼓励每位队员进行头脑风暴。我们深入研究同类产品，力求发

现用户痛点；认真倾听用户需求，将其转化为产品优化的动力。创新始终是我们进步的基石，也是团队软实力的外在体现。通过不断突破技术边界和优化用户体验，我们致力于打造更具竞争力的教育工具。

最后，脚踏实地的实干理念是我们团队精神的根基。我们深知，任何伟大的目标都需要通过一步一个脚印的努力来实现。因此，我们注重细节，严谨对待每一个开发环节，确保产品的稳定性和可靠性。同时，我们始终保持对技术的热爱和对教育的责任感，以实际行动践行团队的理念。

我们的团队理念是：“创新合作，追求卓越”。

5.3 项目进程规划

在明确了项目目标和核心功能后，项目组首先进行了全面的可行性分析，结合市场需求和技术能力，确定了产品的业务需求和发展方向。同时，我们在指导老师的帮助下，深入讨论了产品的功能设计和技术实现路径，明确了开发流程和关键技术节点。

为了确保项目开发的规范性和高效性，同时便于问题追踪和责任划分，项目组对团队成员进行了明确分工，确保每位成员都能充分发挥自身优势。在确认项目需求后，团队对整体开发进度进行了详细评估，并制定了科学的时间规划。表 5-2 是我们团队详细的项目进度图表，它明确了各阶段的任务目标、时间节点和负责人，确保项目按计划稳步推进。

表 5-2 项目开发进度表

开发阶段		项目规划	时间进度	主要负责人
1-项目前期 项目内容熟悉阶段	1.1	相关文献资料查阅	2024.12.12 ~ 2024.12.20	全员
	1.2	寻找同类型竞品并进行调研	2024.12.21 ~ 2025.1.8	全员
	1.3	收集声音数据集及其他素材	2025.1.9 ~ 2025.1.18	全员

2-项目中期 项目模型设计及开发	2.1	● TTS 模型使用及扩展流式语音合成 ● 前端 UI 设计 ● 部署本地 AI 大模型及本地 RAGflow 知识库设计	2025.1.19 ~ 2025.1.27	1. 小马, 小何, 小沈 2. 小林 3. 小杨
	2.2	● 合成语音相似度、MOS 评分等值计算 ● 实现协同过滤推荐算法实现 ● 前端 UI 加强改进 ● 基于SadTalker的虚拟教师技术实现	2025.1.28 ~ 2025.2.17	1. 小马 2. 小杨, 小沈 3. 小林, 小何 4. 小杨, 小马
	2.3	● 用户的辅助学习助手设计 ● 采用 FunASR 服务实现音频提取字幕, 使用 FFmpeg 实现 PPT 到视频的转 变 , 采用 LiberSonora 制作有声书 ● 采用 Spleeter 实现人声与背景音分离, 及混语言音频生成 ● 前后端连接	2025.2.18 ~ 2025.3.7	1. 小杨 2. 小马; 3. 小沈 4. 小林, 小何
	2.4	● 模型打包为 API ● 实现模型部署到硬件 ● 前后端连接	2025.3.8 ~ 2025.3.14	1. 小马, 小杨, 小何 2. 小沈 3. 小林
3-项目后期 文档撰写及资料整理	3.1	● 演示 PPT 制作 ● 结果演示及优化调试 ● 前后端连接	2025.3.15 ~ 2025.3.29	1. 小马 2. 全员
	3.2	● 文档撰写 ● 演示视频拍摄与制作	2025.3.30 ~ 2025.4.5	1. 全员 2. 小沈, 小林
	3.3	文档优化与改进, 项目总结	2025.4.6 ~ 2025.4.9	全员

六、“声动课堂”主要功能展示

6.1 前端总结构

“声动课堂”的前端总体功能结构如图 6-1 所示，她主要包括无障碍适配、语音生成、音色重塑、课件演绎、声动教材、跟读训练、智学对话、AI 助学等 8 个模块。



图 6-1 “声动课堂”前端总体功能结构图

“声动课堂”软件的首页登录注册界面如图 6-2 所示。登录后进入功能界面，其软件总体结构与功能布局如图 6-3 所示。其中，页面左侧为导航栏，右侧界面右上方为用户功能栏，点击用户图标可选择退出登录回到首页界面。



图 6-2 “声动课堂”登录注册界面



图 6-3 “声动课堂”功能界面结构布局

6.2 无障碍适配功能

在图 6-3 的用户功能栏中，用户可选择开启无障碍阅读功能，如图 6-4 所示。开启无障碍阅读功能后，软件页面上方会出现一组无障碍阅读辅助功能栏，用户可以选择开启“盲人读屏”、“十字光标定位辅助”等功能，为视障人群使用本软件提供帮助。



图 6-4 “声动课堂”无障碍阅读功能

主要的无障碍辅助功能栏如下：

- **盲人读屏功能**：开启后系统将自动激活屏幕阅读器，该阅读器能够朗读出软件的文本内容，并描述链接、图片等元素，使得视障用户可以通过听觉来浏览和理解网页信息。此外，它还能识别并朗读动态更新的内容，确保所有用

户都能获取最新信息。

- **纯文本模式**：可将软件的图像等非文本内容转化成文本，并以线性化的方式从上到下显示，以满足不同人群的访问需求。
- **高对比度显示**：将当前软件页面的前景内容和背景的颜色对比调到最大，使得弱视用户也能够清晰地访问网页内容。
- **十字光标定位辅助**：开启后屏幕上会显示一个明显的十字光标，随着鼠标的移动而移动，帮助用户更容易聚焦于特定区域或元素上，使得有视觉障碍但仍有部分视力的用户能够更精准地定位屏幕上的内容。

6.3 语音生成功能

“声动课堂”软件的语音生成功能界面如图 6-5 所示。左侧为功能导航栏，中间上方为教学导入模块，用户可直接在文本框中输入需要生成语音的文本教学内容，或者上传 TXT 格式的文本文件，系统会自动读取文本教学内容。教学内容文本框上方是语音生成细节调整功能栏，支持进行“插入停顿”、“插入笑声”、“插入日期”、“儿化音”、“换气声”等细节调整。用户点击对应按钮后，会在文本中生成对应标记符号，如“<pause>”和“<laughter>”等。



图 6-5 “声动课堂”语音生成功能界面

在教学内容导入模块下方是声音样本选择模块，用户可以选择“克隆人声”和使用“标准音”两种模式，其界面如图 6-6 所示。用户可以点击每个声音样本下方的播放按键试听样本。



图 6-6 声音样本选择栏两种状态的展示

- **标准音模式：**用户切换至标准音时，每种语言中都包含选择的语言的通用标准音和部分地方标准方言，地方标准方言使用当地最具代表性的图标来表示，例如：上海方言使用东方明珠塔图片来表示。
- **克隆人声模式：**用户可以选择使用预设的声音样本，此时只需点击对应的头像即可。也可以根据需要现场新建声音样本，此时点击声音样本末尾的“+”后，出现新建声音样本弹窗，如图 6-7 所示。用户可以通过上传已有的音频文件(.wav)或者现场录制声音进行声音样本的新建，其中音频文件和现场录制都建议使用 5s 到 30s 的单独人声。



图 6-7 新建声音样本窗口

图 6-6 的右侧为音频设置功能模块,用户可以根据需要设置生成的音频“语言”、“情感”、“速度”、“音调”和“音量”等参数。

参数设置完成后(也可以使用系统缺省参数),在图 6-6 的下侧点击“生成音频”按钮,此时软件会生成音频,用户可以点击播放,其界面如图 6-8 所示。




图 6-8 生成音频的播放栏

图 6-8 的左侧为音频控制条,用户可以点击控制音频的播放进度,右侧为音频可视化频谱展示条,此处使用蓝绿色和灰白色来展示音频的播放进度。

6.4 音色重塑功能

音色重塑即“换音”或“声音克隆”功能,主要支持用户上传音频或者视频文件进行声音替换,用户可以选择已有的声音样本或者新建样本录制声音进行声音克隆,其实现界面如图 6-9 所示。其中,其右侧的“音频参数设置”模块、中下侧的“声音样本选择”模块和下侧的“生成音频播放”模块与语音生成功能里的操作方法相同,这里不再赘述。



图 6-9 “声动课堂”音色重塑功能界面

在音色重塑功能界面中间栏红框的上半部分,用户可以点击上传音频或者视频文件,系统自动识别文件类型,利用 ASR 技术提取语音中的文本并展示在右侧的文本栏中。如果用户在“音频参数设置”模块中设置了与文本中不同的语言类型,系统会自动调用翻译模块在红框下半部分的文本栏展示翻译后的文本,并使用翻译的文

本进行声音替换合成处理。

根据文件类型的不同，声音替换处理完成后，如果是音频文件则在界面下方生成语音展示条；如果是视频文件，则跳转到视频预览界面，如图 6-10 所示。在视频预览界面，中间为视频播放展示模块，右侧为历史记录模块，存储近 30 天的视频生成历史记录，并提供下载链接。



图 6-10 “声动课堂”生成视频预览界面

6.5 课件演绎功能

“声动课堂”课件演绎功能界面如图 6-11 所示。该功能界面新增了“虚拟教师”选择栏，用户可以在这里选择虚拟教师形象（也可不选），所选择的虚拟教师形象将出现在生成的教学视频右下方，增加了教学视频的沉浸感。



图 6-11 “声动课堂”课件演绎界面

课件演绎功能界面中间栏上方的红框部分，用户可以上传 PPT 文件，系统自动

读取文件内容，利用 OCR 技术提取文本并传入后台部署的 AI 大模型，生成教学文本后红框右侧的文档栏。同样，如果用户在“音频参数设置”模块设置了与提取文本不同的语言类型，系统会自动调用翻译模块，翻译后的文本也会在红框下半部分展示，同时使用翻译的文本进行声音合成处理。然后，用户需要点击页面下方的“生成视频”按钮，生成视频完成后会跳转到视频预览和播放界面，如图 6-10 所示。

6.6 声动教材功能



图 6-12 “声动课堂”声动教材生成界面

图 6-12 为“声动课堂”声动教材生成界面。用户可在中间栏上传 PDF 格式的教材文件，系统会自动读取文件内容，并展示文件预览，系统后台会利用 OCR 技术提取文本并生成教学语音，生成完成后跳转到声动教材有声书展示界面，如图 6-13 所示。

在有声书展示界面中，左上方为返回按钮，可以返回声动教材生成界面；中间栏为有声书展示行，软件以模拟书页的形式展示并且根据音频播放的时间自动高亮标记当前朗读的文本行。用户可在界面最下方的音频播放栏控制音频播放、暂停、快进快退（5s）和朗读速度外，还可以在暂停状态下直接点击上方的文本模块，音频会自动跳转到对应位置进行播放。



图 6-13 “声动课堂”声动教材有声书展示界面

6.7 跟读训练功能

“声动课堂”的跟读训练功能首先需要选择根据教材，其界面如图 6-14 所示。用户可以在页面上方利用标签筛选教材或者直接使用右侧搜索框搜索教材名称。




图 6-14 “声动课堂”跟读训练教材选择界面

用户点击选中的教材后会进入对应教材的词句跟读界面，如图 6-15 所示。在该界面中如果教材中存在词句两种跟读素材，那么单词的跟读会按照教材中的顺序出现在左侧，句子的跟读会出现在右侧。用户可以点击每个词句右侧的图标按钮进行标准读音的播放，或者点击录音按钮进行跟读，系统会根据跟读的效果进行评分，并展示最新的跟读分数。界面右下角有“评分说明”，用户鼠标悬浮可以查看。



图 6-15 “声动课堂”跟读训练词句跟读界面

6.8 智学对话功能

“声动课堂”的智学对话模块可以为学生错题解析和智能问答提供帮助，其实现界面如图 6-16 所示。用户可以在该界面中间栏上方选择上传错题图片，右侧可以选择 AI 教师的形象和声音。




图 6-16 “声动课堂”智学对话界面（错题识别前）

用户上传完错题图片后，系统会自动在中间栏下方拆分错题为单个题目，并展示该题目的原解与正解。用户可以单选切分出来的单道错题，将该题传入 AI 教师进行答疑，如图 6-17 所示。AI 教师首先会根据错题图片信息对错题进行解析，用户如果对该题还有疑问，可以在下方输入栏中输入问题或者直接进行语音交互，AI 教师会实时回答用户的疑问。



图 6-17 “声动课堂”智学对话界面（识别后）

6.9 AI 助学功能

在“声动课堂”任意界面，点击全局部署的悬浮小机器人，系统会自动展开 AI 助学对话界面，如图 6-18 所示。




图 6-18 “声动课堂”AI 助学对话界面

利用 AI 助学机器人，用户可以随时提问。AI 助学机器人支持多模态交互，能够帮助用户分析 word, pdf, txt 等多种类型的文件，支持实时的语音交互，给用户“面对面交谈”的切实体验。AI 小机器人能够回答广泛的问题，从具体的学术问题到更广泛的知识查询，它利用 NLP 技术理解用户的问题，并通过访问庞大的知识库和算法模型来提供准确的答案。

除了即时答疑外，AI 小机器人还能根据用户的学习习惯，知识掌握程度等信息提供个性化的学习建议和支持。例如，在用户使用跟读训练功能或智学对话时，小

机器人会自动推荐适合当前学习阶段的教材，如图 6-19 和 6-20 所示。而在小机器人弹出推荐弹窗时，点击小机器人进行 AI 对话，则可以进一步查看推荐详情，根据用户历史学习数据，进行具体的练习题或者练习跟读词句的推荐，并指出学习计划中的薄弱环节或提出改进学习方法的建议。



图 6-19 “声动课堂”AI 助学推荐界面（跟读训练推荐）



图 6-20 “声动课堂”AI 助学推荐界面（智学对话推荐）

6.10 启动 API 服务

在之前只能通过手动调用模型的函数来使用 cosyVoice2 模型的功能，通过 FastAPI 框架创建一个 API 服务，并在本地或者服务器上运行，前端就可以通过 API 调用使用模型的函数，方便了前后端的联动。

1. 加载模型并创建 FastAPI 应用

加载 cosyVoice 模型并且设置相关参数来导入模型，通过函数创建 API 应用，并且创建临时目录用来临时存储服务端生成的文件，示例如下：

```
创建 FastAPI 代码示例：
# 创建 API 应用
app = FastAPI()
# 加载 CosyVoice2 和 CosyVoice
cosyvoice_tts = CosyVoice2('pretrained_models/CosyVoice2-0.5B', load_jit=False, load_trt=False, fp16=True)
cosyvoice_vc = CosyVoice('pretrained_models/CosyVoice-300M-SFT', load_jit=False, load_trt=False, fp16=False)
# 创建临时目录
os.makedirs("./temp", exist_ok=True)
```

2. API 端点

提供了四个 API 端点，分别对应了模型的不同函数

表 6-1 API 端点表

API 端点	API 路径	功能
instruct_tts	http://localhost:8000/instruct_tts/	用户上传文本文件，输入指示语句，返回按照该指示语句说出文本的声音
sft	http://localhost:8000/sft/	用户上传文本文件，选择说话人的音色，返回按照该音色说出文本的声音
voice_conversion	http://localhost:8000/voice_conversion/	用户上传两段音频，将其中一段音频的音色替换为另一段音频的
zero_shot_tts	http://localhost:8000/zero_shot_tts/	用户上传文本文件，上传参考音频，返回按照该参考音频的音色说出文本的声音

七、系统优缺点与未来展望

7.1 优点

“声动课堂”在生成音频相似度与自然度、清晰度、实时性、方言和情感控制等方面具有较好优势，具体如下。

7.1.1 发音相似性与自然度

本项目所采用的 CosyVoice2 模型在发音相似性和自然度方面表现出色，它采用 CNN、BLSTM 及组合的神经网络架构，不仅能捕捉局部特征，也能处理全局时间依赖性。这种结构上的优势保证了无论是单个音节还是整个句子的语调和节奏都能被精确模拟，从而提升了整体的自然度和用户的接受度。本项目采用了 Resemblyzer 进行语音相似性的评估，通过从生成的语音中提取深度特征并与原始声音样本对比，确保了两者之间的相似性不低于 85%。

图 7-1 展示了五组相似度评分均值的可视化图，可以看到系统生成音频的相似度达到了 90% 左右。




图 7-1 五组不同音频的相似度评分结果

此外，CosyVoice2 模型不仅使得合成语音能够准确复制原始声音样本的特质，还能在韵律、语调、停顿等方面提供非常自然的声音效果，MOS 评分不低于 4.0，为用户提供了高质量、听起来自然流畅的语音输出体验。

表 7-1 是不同语音合成模型的 MOS 评分性能对比。可以看出，CosyVoice2 模型的 MOS 评分相比其他模型效果更好，生成的语音质量更优。

表 7-1 不同语音合成模型的 MOS 得分性能对比

语音合成模型	MOS 评分
Human	3.84
ChatTTS	3.89
GPT-SoVITs	3.93
CosyVoice	3.93
CosyVoice 2	4.03

MOS 评分使用的模型为 MOSNET，用于预测语音转换系统的平均意见分数，其模型的架构分为三种神经网络架构：

- **卷积神经网络（CNN）**：用于从幅度谱图中提取时间特征
- **双向长短时记忆网络（BLSTM）**：用于捕捉长期的时间依赖性
- **CNN-BLSTM 组合**：结合了 CNN 和 BLSTM 的优势，既能提取局部特征，又能提取全局特征。

评分时，首先输入特征，模型的输入特征为原始幅度谱图，在特征提取之后通过全连接层输出预测的 MOS，目标函数如式（7-1）下：

$$O = \frac{1}{S} \sum_{s=1}^S \left[(\hat{Q}_s - Q_s)^2 + \frac{\alpha}{T_s} \sum_{t=1}^{T_s} (\hat{Q}_s - q_{s,t})^2 \right] \quad (7-1)$$

结合帧级别的预测误差和话语级别的预测误差，从而提高 MOS 预测与人工评分的相关性。

7.1.2 清晰度和实时性

本项目通过 OpenAI 的语音识别库对生成的语音进行识别，并将识别结果与原文本比较后进行相似度归一化处理，以 0 到 1 的分数评估清晰度。这种方法使得 CosyVoice2 的清晰度得分为 0.89，意味着系统能有效去除背景噪音并提升语音质量，即使在嘈杂环境中也能保持良好的可理解度。

考虑到教育和技术应用场景的需求，CosyVoice2 的流式输出设计保证了从接收

文本到输出语音的响应时间平均为 1.39 秒。该响应时间受服务器性能影响，本项目使用的服务器为 A5000 显卡，显存为 28G。本项目的响应时间测评结果如图 7-2 所示。

```
2025-03-15 13:36:45,083 INFO synthesis text 同学们，大家好！今天我们来聊一聊一个非常有趣且重要的主题 算法入门。在当今数字化的时代，算法无处不在，它就像是隐藏在各种设备和软件背后的“魔法师”，悄无声息地影响着我们的生活。
2025-03-15 13:36:48,954 INFO yield speech len 1.84, rtf 2.103852577831434
Generated 1 audio segments, saving to 'zero_shot_combined.wav'...
2025-03-15 13:36:51,219 INFO yield speech len 2.0, rtf 1.1266429424285889
Generated 2 audio segments, saving to 'zero_shot_combined.wav'...
2025-03-15 13:36:53,572 INFO yield speech len 2.0, rtf 1.1701127290725708
Generated 3 audio segments, saving to 'zero_shot_combined.wav'...
2025-03-15 13:36:56,360 INFO yield speech len 2.0, rtf 1.3882108926773071
Generated 4 audio segments, saving to 'zero_shot_combined.wav'...
2025-03-15 13:36:58,810 INFO yield speech len 2.0, rtf 1.216381549835205
Generated 5 audio segments, saving to 'zero_shot_combined.wav'...
```

图 7-2 响应时间测评结果

由图可知，系统的响应时间短，速度快。这种快速的响应速度支持即时交互场景，如在线课堂讲解、虚拟教师辅导等，提高了教学效率和用户体验。

另外，在流式输出方面，CosyVoice2 相较于其他模型有着更低的延迟，几乎无损的质量和极强的稳定性的优势。不同模型之间的流式输出对比如表 7-2 所示。

表 7-2 不同模型的流式输出对比

模型	首包延迟	流式支持
CosyVoice 2	150ms	双向流式，无损质量
Seed-TTS	300ms	非流式优先
ChatTTS	500ms	有限流式支持
LiveSpeech	200ms	仅支持自回归流式

7.1.3 方言和情感控制

本系统采用的 CosyVoice2 模型在方言控制和情感细腻度的控制方面远远优于其他同类模型，可控制的选项更多，生成的效果也更好。CosyVoice2 可以通过自然语言指令（如“用四川话 + 高兴的语气”）直接组合方言和情感，无需分步处理，对比 Seed-TTS 需分别调用方言模型和情感模型，CosyVoice2 处理流程更为简单。另外，CosyVoice2 在长文本合成（如 30 分钟有声书）中，情感和方言稳定性显著优于 ChatTTS。

表 7-3 为不同模型对方言支持的对比，从中可以看出，CosyVoice2 覆盖 6+ 种中文方言，且通过指令方便切换，灵活度远超同类竞品。

表 7-3 不同模型的方言支持对比分析

模型	支持方言	跨语言合成能力	方言自然度 (MOS 评分)
CosyVoice 2	粤语、四川话、上海话、郑州话、长沙话、天津话等	支持跨语言（如中文→粤语）	4.8/5.0（粤语测试）
Seed-TTS	粤语、闽南语等	部分支持跨语言	4.5/5.0
ChatTTS	仅标准普通话	不支持跨语言	4.0/5.0
OpenVoice	粤语、英语方言	支持跨语言克隆	4.3/5.0
GPT-SoVITS	粤语、部分方言	有限跨语言支持	4.2/5.0

表 7-4 为不同模型的情感支持对比。由表可知，CosyVoice2 支持 8 种基础情感 + 角色扮演，细粒度标签实现精准控制（如插入呼吸声），性能也优于其他模型。

表 7-4 不同模型的情感支持对比分析

模型	情感类型	控制方式	情感自然度 (MOS 评分)
CosyVoice2	高兴、悲伤、愤怒、恐惧、厌恶、冷静、严肃等 8 种基础情感 + 自定义角色（如机器人、小猪佩奇）	自然语言指令 + 细粒度标签（如 强调、[laughter]）	4.06/5.0
Seed-TTS	快乐、悲伤、惊讶、愤怒等 6 种	文本前缀标注（如 [happy]）	3.8/5.0
ChatTTS	中性、快乐、悲伤等 4 种	有限文本提示	3.5/5.0
EmotiVoice	2000+ 音色库，情感依赖音色	音色选择 + 简单文本修饰	3.7/5.0
GPT-SoVITS	主播风格（如激情、温柔）	依赖音色克隆	3.6/5.0

7.1.4 技术创新与适应性

本项目所开发的“声动课堂”AI 语音教学辅助系统具有以下创新性和适用性。

- (1) **一体化解决方案。**系统通过整合 CosyVoice2、Spleeter 和 SadTalker 等多种前沿 AI 技术，提供了从音频输出到虚拟教师视频的完整解决方案，包括个性化音色克隆、声音分离及 3D 数字人展示等功能，为教育内容创作者和学

生提供了一个全面的教学辅助工具。

- (2) **广泛的适用性**。“声动课堂”具有 6 个核心模块,支持无障碍适配、语音生成、音色重塑、课件演绎、声动教材、跟读训练、智学对话、AI 助学等 8 大功能,不仅适用于各类教育阶段,还能服务于职业教育、语言培训及特殊教育等场景,满足不同用户群体的需求。
- (3) **无障碍适配功能**。考虑到视障或阅读困难的学生群体,“声动课堂”提供了无障碍阅读功能,包括盲人读屏、十字光标定位辅助等功能,帮助所有用户更方便地获取信息和学习,体现了人文关怀和社会责任。
- (4) **智能化流程提升效率**。“声动课堂”利用 AI 大语言模型自动提取并优化讲稿,结合快速合成高质量音频的能力,显著提升了教育内容创作的效率。相比传统人工录制方式,软件能更快速地完成文本到音频的转换,并支持批量处理多页 PPT,节省了大量时间。
- (5) **互动式虚拟教师技术增强课堂活跃性**。“声动课堂”凭借生动逼真的形象与智能交互能力,虚拟教师能够在课堂上与学生展开多样化互动,无论是趣味问答、情景模拟还是知识讲解,都能充分吸引学生的注意力,显著增强课堂的活跃氛围。相较于传统单一的教师授课模式,“声动课堂”虚拟教师的多元表现形式能够激发了学生的参与热情,让课堂充满活力。
- (6) **多语言支持与个性化定制**。系统所采用的 CosyVoice2 声音合成模型不仅支持多种语言及方言的跨语种合成,还允许根据用户的个性化需求调整语速、语调、语气等参数,增强了系统的灵活性和适应性。此外,利用认知感知型智能推荐系统,系统可以为用户提供更加个性化的服务体验,打破了传统“一刀切”教学模式的局限,动态调整教学内容和方式,满足不同学习者的需求,大幅提升学习效率。

7.1.5 政策支持与市场机遇

本项目开发的“声动课堂”AI 语音教学辅助系统符合国家当前的教育发展战略,且有着广阔的市场前景。

- (1) **符合国家教育数字化战略**。本项目积极响应国家关于推进教育信息化 2.0 行动计划的号召,通过技术创新助力教育资源的数字化普惠、个性化教学及教学场景智能化,符合国家战略方向。
- (2) **广阔的市场需求**。当前在线教育市场的快速增长及混合式教学模式的兴起为本项目““声动课堂”的开发提供了广阔的发展空间,特别是在北美、东南亚

等地，随着教育数字化渗透率的持续提升，具有多语言支持能力的软件将迎来更多机会。

7.2 缺憾与不足

由于开发时间有限，本项目当前尚存在着一些缺憾与不足，需要未来不断探索和优化。

- (1) **高开发与维护成本**。项目开发集成多种先进技术，虽然提升了功能多样性，但也显著增加了开发和维护难度，要求专业技术团队投入大量时间和精力进行调试与优化，初期市场规模有限时可能影响项目的财务可持续性。
- (2) **用户接受度的风险**。尽管 AI 虚拟教师和声音置换等新颖功能在技术上取得了突破，但部分用户可能仍倾向于传统的真人教学模式，需要一定的时间来适应新技术带来的变化。
- (3) **品牌认知度较低**。作为一款全新的 AI 教育产品，“声动课堂”尚没有品牌知名度，在面对成熟的竞争对手时，可能难以迅速获得用户的信任和支持。

7.3 未来展望

7.3.1 未来潜力和优化空间

尽管“声动课堂”这种新型的 AI 语音教育辅助系统尚处于初步开发阶段，但在当前 AI 改变世界、教育改变命运的时代，她未来有着巨大的发展潜力。以下是本项目的优化空间。

- (1) **改进计算效率与降低成本**。探索更加高效的算法架构，如进一步优化模块间的耦合性，减少技术复杂性的同时降低维护成本；同时，加强与技术提供商的合作，获取技术支持以减轻负担。
- (2) **增强多语言支持**。随着全球范围内对多语言支持需求的增长，将进一步扩展并优化 CosyVoice2 对更多语言的支持，特别是那些资源较少的语言。
- (3) **个性化服务深化**。利用认知感知型智能推荐系统等先进技术，提供更加个性化的服务体验，根据用户的学习习惯和偏好动态调整教学内容和方式。未来将通过与学校合作试点项目，逐步帮助师生适应 AI 教学模式，并设立用户反馈机制，依据收集的意见不断优化产品，提高用户满意度。
- (4) **持续技术创新**。紧跟人工智能领域的最新进展，不断引入新的技术和方法，

如改进的 Informer 深度知识追踪模型，以提高系统的整体效能和服务质量。

- (5) **教育公平的推进**。通过引入方言和地方特色教育资源，帮助教育资源匮乏地区的同学获取更优质的教育资源，促进教育公平的实现。

7.3.2 未来展望

本团队在后续的工作中将对与用户的语音交互模块展开拓展。我们计划引入先进的声纹识别技术，搭建起一套精准且高效的用户特征感知体系。通过对用户语音信号的全方位解析，不仅能够敏锐地捕获用户当下的情感状态，诸如疑惑、疲惫、兴奋、沮丧等，还能凭借前沿算法推算出用户的大致年龄范围。

在捕获到这些信息后，将它们巧妙地运用到对虚拟教师语音输出的精细化控制当中。如当系统感知到用户的提问语音中蕴含着较为疑惑的情感时，虚拟教师将自动调用深度解答模式，以更加详尽、细致的语言，配合丰富的案例和清晰的逻辑，为用户层层剖析问题，确保用户能够完全理解。若系统检测到用户的情感处于较为疲惫的状态，虚拟教师会立即对自身语速进行适当调整，放缓语速的同时，语调也会变得更加温和舒缓，就如同一位贴心的陪伴者，给予用户更舒适的交互体验。

此外，针对不同年龄层和性别用户，虚拟教师也会展现出差异化的语音输出风格。面对年轻用户，虚拟教师的语音将更具活力与时尚感，使用当下流行的词汇和表达方式，迅速拉近与用户的距离；而对于年长用户，虚拟教师则会采用更为沉稳、庄重的语调，以符合他们的沟通习惯。通过这样全面且个性化的语音输出控制，我们致力于打造出更加智能、贴心、人性化的虚拟教师语音交互体验，让每一位用户都能在与虚拟教师的交流中感受到专属的关怀与满足。

同时，我们计划开发一种能够自动从上传的有声视频或音频内容中提取关键信息的功能。这一功能将结合先进的语音识别技术和自然语言处理算法，实现对音频内容的深度解析。通过分析演讲者的声音特征、语调变化以及关键词汇，系统能够智能地识别出哪些部分是重点内容，并自动生成简洁明了的摘要。这不仅能够帮助用户快速掌握核心知识，还能极大地节省他们筛选有用信息的时间。

之后我们还计划引入一个创新的思维导图生成功能。该功能将在上述自动提取重点的基础上，进一步将这些要点以图形化的方式展示出来，形成直观易懂的知识结构图。这种可视化工具对于促进记忆和理解非常有效，尤其是对于那些视觉型学习者而言，它提供了一个全新的视角去理解和吸收复杂的信息。同时，用户可以根据自己的需求对生成的思维导图进行编辑和调整，添加个人见解或链接到其他相关资源，从而构建起属于自己的个性化知识网络。

八、商业计划

8.1 成本分析

本节对本项目的成本进行分析，包括人力成本、算力成本、开发成本、维护成本四部分，具体如表 8-1 所示。

表 8-1 项目成本分析表

成本类型	成本描述	共计
人力成本	开发阶段需 5 人团队，包括 2 名 AI 工程师、1 名前端开发、1 名后端开发工程师和 1 名测试人员，开发周期为 4 个月，平均薪资 1W/月。	20 万元
算力成本	租用 4 卡 A100 服务器和 8 卡 A800 服务器进行训练，预计每月成本约 3 万元，训练时长为一个月。	3 万元
开发成本	软件部署支持预计 5000 元，项目管理 5000 元，开发过程的云服务器试用预计每月成本 5000 元，开发时常为 2 个月。	总计 3 万元
维护成本	维护成本覆盖后期软件运营维护费用与升级费用，后期运营维护费用主要对该平台在后期运营期间需要根据运营时发生的各种问题进行维护，及时修补漏洞；升级费用主要针对实际运营中产生的需求的变化或实际硬件环境的变化而进行部分或全部的修改而达到实际需求而产生的费用。	预计每年 3 万元

8.2 市场分析

8.2.1 宏观市场分析

1. 政治因素

2018 年，国家教育部发布《教育信息化 2.0 行动计划》，提出推动人工智能、大数据等技术在教育中的深度应用，提升教育资源供给能力，促进教育公平。工信部《国家人工智能产业综合标准化体系建设指南（2024 版）》明确智能语音技术要求，包括方言识别、情感化语音合成等标准，为行业提供研发方向。2025 年全国两会期间，习近平总书记在政协教育界联组会上提出实施国家教育数字化战略，强调建设学习型社会，为 AI 教育辅助工具提供了强有力的政策支持。本公司 AI 语音合成为基础，结合数字人，语言大模型，追踪算法等技术，打造一款智能 AI 教学辅助

软件，顺应国家政策，推动教育数字化发展。

2. 经济因素

“声动课堂”在经济环境下面临广阔发展机遇。我国在线教育市场规模预计 2025 年超过 6000 亿元，年增长率 15%，全球市场同步扩张，为 AI 教育工具提供了强劲需求支撑；人均收入水平持续提升，居民人均可支配收入达 41314 元，城镇居民收入增速超 4.6%，农村居民收入增速达 6.6%。县域教育消费能力显著提升，增强了个人用户对订阅服务的付费能力；同时，教育支出占比稳步提高，如图 8-1 所示，城镇家庭教育花费占收入的 11.3%，中小机构年均数字化预算 10~20 万元，表明用户和机构愿意为优质教育资源投资，声动课堂具有巨大的发展潜力。




图 8-1 2024 年全国及分城乡居民人均可支配收入




图 8-2 2024 年居民人均消费支出及构成

3. 社会因素

(1) 用户痛点与需求

据调研，而教师而言，在备课方面，63%的教师每日备课耗时超 3 小时，70%的教师希望高效生成备课内容；在方言限制方面，西南地区教师普通话达标率仅 58%，方言语音克隆功能可生成标准普通话教学素材。对于学生群体来说，在个性化方面，60%的学生青睐互动性强的资源，而虚拟教师与音色克隆等功能恰好可以击中这一痛点；在口语学习方面，78%的中学生因为担心英语发音与听力问题而感到焦虑，AI 发音纠错功能通过实时评分提升学习信心。

(2) 技术接受度与文化适配

- **年龄结构。**对于新生代教师与大多数学生来说，更易接受 AI 辅助工具，而对于部分教师与学生来说，他们可能更喜欢传统教学与真人互动的方式，可以通过免费试用和提供教程的方式来增加他们的接受度。
- **地域文化差异。**在一些地区提供方言语音包，契合“中华文化遗产”政策，拓展增量市场。

4. 技术因素

当前 AI 技术的井喷式发展，为我们的产品提供了很好的技术保证。CosyVoice 的零样本音色克隆、Spleeter 的音频分离和 SadTalker 的唇同步技术已日趋成熟，通过 WebAssembly 和云端 API 集成，可在浏览器高效运行，生成个性化音频和动态视频，仅需普通设备即可流畅使用。5G 和云计算普及进一步支持网页应用的低延迟体验，目标响应时间 200ms 以内，契合在线教育对实时互动的需求。然而，技术迭代迅速，新一代 TTS 或 AI 模型可能超越现有技术，本公司也会持续研发保持声动课堂的产品竞争力。

8.2.2 SWOT 战略分析

1. 优势 (Strengths)

- (1) **技术融合创新。**“声动课堂”通过深度整合多种前沿 AI 技术，构建了独具特色的一体化教育解决方案。CosyVoice 的零样本音色克隆与高保真语音合成技术赋予软件个性化音频生成能力；Spleeter 基于深度学习的音频分离技术能够高效分解人声与伴奏，为声音置换提供精准支持 SadTalker 的 3D 建模与唇同步技术则实现动态数字人展示，赋予虚拟教师生动表现力。与市场上常见的单点技术产品相比，“声动课堂”在技术广度和深度上的创新为其奠定了

显著竞争优势。

- (2) **功能多样性。**“声动课堂”提供 6 大核心功能 8 个功能模块，全面覆盖教育内容创作和学生学习的各种需求，不仅支持各阶段的教育还能服务于职业教育、语言培训和特殊教育等场景，适用性广泛。
- (3) **高效内容生成。**“声动课堂”通过智能化流程显著提升教育内容创作效率。利用 AI 大语言模型从 PPT 中自动提取并优化讲稿，结合 CosyVoice 模型快速合成高质量音频，用户无需手动录制即可生成专业教学资源。相比传统人工录制，软件能快速完成文本到音频的转换，并支持批量处理多页 PPT。这种高效性不仅节省时间，还能帮助教育机构快速构建资源库，让教师专注于教学设计而非技术操作，为教育内容创作带来了革命性的便利。
- (4) **用户体验优化。**“声动课堂”支持个性化音色、虚拟教师视频、AI 助手问答等，提升教学内容的吸引力和互动性，增强学生学习兴趣。同时我们还专门针对视障人群，制作了无障碍地使用软件，实现教育公平，保证了每一位用户的使用体验。

2. 劣势 (Weaknesses)

(1) 技术复杂性与维护成本

“声动课堂”集成了多种先进的技术，大大提升了功能的多样性，但这也显著增加了开发和维护难度，不同技术模块的兼容性调试与优化都要专业技术团队投入大量的时间与精力，同时如果一项技术出现了故障，开发团队也需要快速相应，这进一步提高了人力与资源的需求，在初期市场规模有限时，对项目的财务可持续性构成挑战。

解决措施：为降低技术复杂性和维护成本，可采用模块化设计，将 CosyVoice、Spleeter 等核心功能独立封装，减少模块间的耦合性，便于单独更新和维护。同时，建立技术文档和自动化测试体系，减少人工调试时间。此外，与技术提供方建立合作关系，获取技术支持和优化方案，降低系统维护负担。

(2) 用户接受度不确定

教育者和学生对 AI 虚拟教师 and 声音置换等创新功能的接受程度仍存在不确定性。尽管这些功能在技术上具有突破性，但部分用户可能更习惯或信任传统的真人教学模式。

解决措施：可以与学校展开合作试点，提供培训支持，逐步帮助广大师生适应 AI

教学模式；同时设定用户反馈机制，收集用户的建议不断的优化产品，增强用户信任。

（3）市场认知度低

作为一款全新产品，“声动课堂”在教育科技市场中的品牌知名度几乎为零。与成熟的竞争对手相比，缺乏品牌积累意味着用户对其功能和可靠性的信任度较低，用户在选择时可能更注重品牌效应。

解决措施：制定明确的品牌定位，通过独特的品牌故事和形象吸引消费者。运用有效的营销策略，通过社交媒体（微信、抖音）发布教学案例视频，展示“声动课堂”的独特功能，吸引早期用户。同时也可以与华为等知名品牌展开合作活动，借助其品牌效应和渠道快速触达目标用户，提高品牌知名度和美誉度。

3. 机会（Opportunities）

- （1）**政策支持。**早在 2018 年就提出了《教育信息化 2.0 行动计划》，规划了未来教育发展数字化的道路。最新的教育工作会议中，明确指出了要推动教育公平和职业教育数字化，鼓励 AI 技术应用。
- （2）**市场需求。**在线教育市场呈现爆发式增长态势，根据《中国在线教育行业发展报告（2023）》，预计到 2025 年市场规模将超过 6000 亿元，年均复合增长率达 15%。与此同时，混合式教学模式逐渐成为教育行业的主流趋势，推动了对智能化、便携式教学工具的旺盛需求。这种需求不仅限于国内，全球教育科技市场也在快速扩张，尤其在北美、东南亚等地区，教育数字化渗透率持续提升，为多语言支持的软件开辟了广阔的海外市场空间。
- （3）**个性化需求。**随着学生对个性化学习体验的追求日益强烈，传统单一的教学资源已难以满足其需求。调查显示，超过 60% 的学生希望学习内容更具互动性和趣味性，而音色克隆和虚拟教师等技术正契合这一趋势。

4. 威胁（Threats）

- （1）**技术竞争风险。**其他同类的 TTS 工具（如百度 AI）、数字人平台（如 VTube Studio）或教育软件可能推出类似功能，形成竞争压力。
- （2）**技术更新风险：**AI 和边缘计算技术快速迭代，若不能及时跟进，可能丧失技术优势。

8.3 盈利模式

本项目所开发的“声动课堂”AI 教育软件的盈利模式如下：

- (1) **订阅制盈利。**针对个人用户，提供基于订阅的软件服务，基础版定价为 25 元/月，包年优惠价为 198 元/年，包含音频输出，有声课件，有声书等功能；高级版定价为 50 元/月，包年优惠价为 298 元/年，相较于基础版本增加了发声练习，声音置换，AI 教师等功能。此外，为了吸引用户使用，对于刚注册的新用户，首月我们提供高级版免费试用。这种模式通过低门槛定价和灵活套餐，满足个人用户的多样化需求，同时保证稳定的现金流。
- (2) **机构销售盈利。**面向教育机构（如学校、培训机构、在线教育平台等），提供批量授权许可。定价为 20W/年，包含 500 个用户账号，支持所有功能，并提供技术支持与定制化服务。此模式利用机构对高质量教学资源的需求，确保大额收入，同时通过定制化增强客户黏性。
- (3) **增值服务盈利。**提供增值服务和付费内容包，增加收入来源。例如，推出一些动漫形象或者知名播音员的语音包，定价 20 元/个，满足个性化需求；提供“专业课件模板”，定价 50 元/套，方便快捷生成高质量内容。此模式通过低成本数字产品提升用户体验，同时创造额外利润点。
- (4) **广告合作盈利。**与一些图书与课程经销商合作，挑选一些优质的课程与图书，再根据用户的实际使用情况，利用追踪算法来推荐图书与课程，来补足用户的薄弱点。这种模式根据用户的需求来实现现金流的转换，保证了双方共同的利益。

8.4 营销策略

“声动课堂”通过多层次营销策略，快速建立品牌影响力，吸引个人用户和教育机构，实现市场突破。

1. 教育展会与线下活动

考虑到本项目在发展初期知名度不高、缺乏品牌优势的情景，在发展初期本公司会参加一些教育展会与举办一些线下活动，设置互动体验区，让观众现场测试声音置换和虚拟教师功能，通过交互体验来增加产品的知名度与建立品牌优势。

2. 社交媒体营销

利用自媒体平台（如抖音、微博）推广“声动课堂”，聚焦教育创作者和学生群体。

发布短视频展示功能亮点。同时，运营微信公众号和教育论坛，分享教学案例和使用教程，吸引关注者下载试用。通过这些手段形成账号矩阵和链式传播系统，用于品牌形象建立以及建立公共关系和用户互动等功能。

3. 教育机构合作与试点推广

为快速打入教育市场，“声动课堂”将与学校、培训机构及在线教育平台建立合作关系。通过提供试点机会，让这些机构免费体验软件的全功能，感受其在教学中的高效性和实用性。试点期间，团队将收集使用反馈和成功案例，用于优化产品并打造可信赖的品牌形象。试点结束后，向合作机构推出定制化的授权服务，满足其特定需求，如专属音色或功能集成。这种策略通过与教育机构的深度合作，提升软件的专业认可度，同时为后续推广提供真实案例支持，吸引更多潜在客户。

九、参考文献

- [1] 教育部. 教育部关于印发《教育信息化 2.0 行动计划》的通知: 教技〔2018〕6 号 [A/OL]. 中国政府网_中央人民政府门户网站. https://www.gov.cn/zhengce/zhengceku/2018-12/31/content_5443362.htm, 2018-04-13.
- [2] 教育部. 新时代基础教育强师计划[EB/OL]. 中国政府网-中央人民政府门户网站, www.gov.cn, 2022-04-14.
- [3] 沙鹏程. 多措并举推动义务教育优质均衡发展 [EB/OL]. 中国政府网_部门动态, https://www.gov.cn/lianbo/bumen/202307/content_6890407.htm, 2023-07-07.
- [4] 一见·两个维度, 看总书记部署教育数字化 [EB/OL]. 人民网, <http://lianghui.people.com.cn/2025/n1/2025/0312/c460142-40437724.html>, 2025-03-12.
- [5] 杨鹤. 2025 年全国教育工作会议召开 [EB/OL]. 中国政府网_部门动态, https://www.gov.cn/lianbo/bumen/202501/content_6997576.htm, 2025-01-10.
- [6] UMEDA N, TERANISHI R. The parsing program for automatic text-to-speech synthesis developed at the electrotechnical laboratory in 1968 [J/OL]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1975.
- [7] KLATT D H. Review of text-to-speech conversion for English[J/OL]. The Journal of the Acoustical Society of America, 1987.
- [8] OORD A van den, DIELEMAN S, ZEN H, et al. WaveNet: A Generative Model for Raw Audio[A/OL]. arXiv, 2016.
- [9] WANG X, JIANG M, MA Z, . Spark-TTS: An Efficient LLM-Based Text-to-Speech Model with Single-Stream Decoupled Speech Tokens[A/OL]. arXiv, 2025.
- [10] DU Z, CHEN Q, ZHANG S, et al. CosyVoice: A Scalable Multilingual Zero-shot Text-to-speech Synthesizer based on Supervised Semantic Tokens[A/OL]. arXiv, 2024.
- [11] HENNEQUIN R, KHLIF A, VOITURET F, et al. Spleeter: a fast and efficient music source separation tool with pre-trained models[J/OL]. Journal of Open Source Software, 2020.
- [12] DU Z, WANG Y, CHEN Q, et al. CosyVoice 2: Scalable Streaming Speech Synthesis with Large Language Models[A/OL]. arXiv, 2024.
- [13] Fabian Mentzer, David Minnen, Eirikur Agustsson, and Michael Tschannen. Finite scalar quantization: VQ-VAE made simple. In ICLR. OpenReview.net, 2024.
- [14] Tongyi Speech Team. Funaudio11m: Voice understanding and generation foundation models for natural interaction between humans and llms. arxiv, 2024.
- [15] Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D. Manning, Stefano

- Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. In NeurIPS, 2023.
- [16] 殷涛. 基于 Informer 的深度知识追踪方法研究与应用[D]. 南昌大学, 2024.
- [17] 荆斐. 基于认知诊断和协同过滤的个性化试题推荐方法研究与应用[D]. 河南大学, 2023.
- [18] Chenxu Zhang, Yifan Zhao, Yifei Huang, Ming Zeng, Saifeng Ni, Madhukar Budagavi, and Xiaohu Guo. Facial: Synthesizing dynamic talking face with implicit attribute learning. In ICCV, 2021.3